Tarea 2 - MDS7104 Aprendizaje de Máquinas

Felipe Muñoz Marín [* 1]

Abstract

This work addresses two core machine learning problems: Bayesian inference and nonlinear regression via MLE. In the first part, the Beta-Bernoulli model was studied, deriving the MAP, MLE, and posterior mean estimators, and verifying Bayesian consistency across four different priors. A key result was showing that the MLE variance estimator coincides exactly with the least squares estimator. In the second part, the Amazon Reviews 2023 dataset was used to fit polynomial and sinusoidal regression models. Degree 3 polynomial was selected for its best train/test balance, and sinusoidal components were added to capture seasonality. Convergence was only achieved by switching to Nelder-Mead optimization, yielding an 18% reduction in test MSE. Nevertheless, the final model presents $R^2 \approx 0$ on test and heteroscedasticity, suggesting Poisson or negative binomial distributions would be more appropriate for count data.

1. Inferencia Bayesiana: Modelo Beta-Bernoulli

1.1. Distribución posterior conjugada y comparación de estimadores en el modelo Beta-Bernoulli

1.1.1. Distribución posterior conjugada

Se tiene que, dado $X_i \sim \text{Bernoulli}(\theta)$ i.i.d., la verosimilitud conjunta del modelo es:

$$\begin{aligned} p(X \mid \theta) = \prod_{i=1}^{n} p(X_i \mid \theta) &= \prod_{i=1}^{n} \theta^{x_i}(1-\theta)^{1-x_i} \\ &= \theta^s(1-\theta)^{n-s} \end{aligned}$$

donde $s = \sum_{i=1}^{n} x_i$ denota el número de éxitos observados (obtener cara).

Dado el prior $\theta \sim \text{Beta}(\alpha, \beta)$, cuya densidad es:

$$p(\theta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\,\Gamma(\beta)}\,\theta^{\alpha-1}(1-\theta)^{\beta-1}$$

por el Teorema de Bayes, la distribución posterior satisface:

$$\begin{aligned} p(\theta \mid X) &\propto p(X \mid \theta)\,p(\theta) \\ &\propto \theta^s(1-\theta)^{n-s} \cdot \theta^{\alpha-1}(1-\theta)^{\beta-1} \\ &= \theta^{(s+\alpha)-1}(1-\theta)^{(n-s+\beta)-1}. \end{aligned}$$

Definiendo $\alpha' = \alpha + s$ y $\beta' = \beta + n - s$, se reconoce que esta expresión es proporcional a una distribución $\text{Beta}(\alpha', \beta')$. Como la densidad posterior debe integrar 1, la constante de normalización queda determinada de la siguiente manera:

$$p(\theta \mid X) = \frac{\Gamma(\alpha'+\beta')}{\Gamma(\alpha')\,\Gamma(\beta')}\,\theta^{\alpha'-1}(1-\theta)^{\beta'-1}$$

Por lo tanto: $p(\theta \mid X) \sim \text{Beta}(\alpha', \beta')$. Dado que la posterior pertenece a la misma familia de distribución que el prior, se concluye que la distribución Beta es un prior conjugado para la verosimilitud Bernoulli.

1.1.2. Estimador Puntual Bayesiano y MLE

El estimador puntual bayesiano corresponde a la media de la distribución posterior, obtenida aplicando el operador esperanza:

$$\begin{aligned} \bar{\theta} = \mathbb{E}[\theta \mid X] &= \int_0^1 \theta \cdot p(\theta \mid X)\,d\theta \\ &= \frac{\Gamma(\alpha'+\beta')}{\Gamma(\alpha')\,\Gamma(\beta')} \int_0^1 \theta^{\alpha'}(1-\theta)^{\beta'-1}\,d\theta \end{aligned}$$

Notar que, a integral $\int_0^1 L_n(\theta)\pi(\theta)d\theta$ se resuelve por conjugación: Al reconocer que la integral resultante corresponde al kernel de una $\text{Beta}(\alpha'+1, \beta')$, se tiene que:

$$\int_0^1 \theta^{(\alpha'+1)-1}(1-\theta)^{\beta'-1}\,d\theta = \frac{\Gamma(\alpha'+1)\,\Gamma(\beta')}{\Gamma(\alpha'+1+\beta')}$$

y aplicando la propiedad $\Gamma(z+1) = z\Gamma(z)$, se obtiene:

$$\begin{aligned} \Rightarrow \bar{\theta} = &= \frac{\Gamma(\alpha'+\beta')}{\Gamma(\alpha')\,\Gamma(\beta')} \cdot \frac{\Gamma(\alpha'+1)\,\Gamma(\beta')}{\Gamma(\alpha'+1+\beta')} \\ &= \frac{\Gamma(\alpha'+\beta')}{\Gamma(\alpha')\,\Gamma(\beta')} \cdot \frac{\alpha'\Gamma(\alpha)\,\Gamma(\beta')}{(\alpha'+\beta')\Gamma(\alpha'+\beta')} \\ &= \frac{\alpha'}{\alpha'+\beta'} \end{aligned}$$

Sustituyendo $\alpha' = \alpha + s$ y $\beta' = \beta + n - s$, el estimador puntual bayesiano (media posterior) es:

$$\bar{\theta} = \frac{\alpha + s}{\alpha + \beta + n} \tag{1}$$

Para el estimador de Máxima Verosimilitud (MLE), se maximiza la log-verosimilitud, aprovechando que el logaritmo es una transformación monótona creciente que preserva el máximo:

$$\hat{\theta}_{\text{MLE}} = \arg\max_{\theta} p(X \mid \theta) = \arg\max_{\theta} \ell(\theta)$$

Aplicando condición de primer orden:

$$\frac{\partial}{\partial\theta}\Big(\ln[\theta^s]\Big) + \frac{\partial}{\partial\theta}\Big(\ln[(1-\theta)^{n-s}]\Big) = 0$$
$$\frac{s}{\theta} - \frac{(n-s)}{1-\theta} = 0$$

Donde, se obtiene directamente:

$$\hat{\theta}_{MLE} = \frac{s}{n} \tag{2}$$

Ambos estimadores coinciden cuando $\alpha = \beta = 0$, pues en ese caso $\bar{\theta}_{\text{Bayes}} = s/n = \hat{\theta}_{\text{MLE}}$. Sin embargo, esta condición implica un prior $p(\theta) \propto \theta^{-1}(1-\theta)^{-1}$, que no es una distribución de probabilidad propia (no integra a 1 sobre $[0,1]$) y concentra toda su masa en los extremos $\theta = 0$ y $\theta = 1$. Desde una perspectiva práctica, la coincidencia entre ambos estimadores se da de forma aproximada cuando los hiperparámetros α y β son pequeños en relación al tamaño de los datos n, es decir, cuando el prior es débil y los datos dominan la inferencia del modelo.

1.2. Distribución predictiva y estimador MAP en el modelo Beta-Bernoulli

1.3. Distribución Predictiva y Estimador MAP

1.3.1. Distribución Predictiva

La distribución predictiva para una nueva observación X_{n+1} integra la incertidumbre sobre θ marginalizando sobre la posterior y todos los valores posibles, es decir:

$$\begin{aligned}\mathbb{P}(X_{n+1} = 1 \mid \mathcal{D}_n) &= \int_0^1 \mathbb{P}(X_{n+1} = 1 \mid \theta)\, p(\theta \mid \mathcal{D}_n)\, d\theta \\ &= \int_0^1 \theta \cdot p(\theta \mid \mathcal{D}_n)\, d\theta \\ &= \mathbb{E}[\theta \mid \mathcal{D}_n]\end{aligned}$$

Como se demostró en la sección anterior, $\theta \mid \mathcal{D}_n \sim \text{Beta}(\alpha', \beta')$ con $\alpha' = \alpha + s$ y $\beta' = \beta + n - s$, por lo que, por la ecuación (1):

$$\mathbb{P}(X_{n+1} = 1 \mid \mathcal{D}_n) = \frac{\alpha'}{\alpha' + \beta'} = \frac{\alpha + s}{\alpha + \beta + n} \tag{3}$$

La regla de sucesión de Laplace establece que, si se han observado s éxitos en n ensayos, la probabilidad de éxito en el siguiente ensayo es $(s+1)/(n+2)$. Este resultado se obtiene como caso particular de (3) bajo el prior uniforme $\theta \sim \text{Beta}(1,1)$, es decir, con $\alpha = \beta = 1$:

$$\mathbb{P}(X_{n+1} = 1 \mid \mathcal{D}_n)\big|_{\alpha=\beta=1} = \frac{1+s}{2+n} = \frac{s+1}{n+2}$$

Este resultado indica que, el prior uniforme actúa como si se hubieran observado un éxito y un fracaso ficticios antes de ver cualquier dato, lo que evita las probabilidades extremas 0 y 1 que produciría el MLE cuando $s = 0$ o $s = n$.

1.3.2. Estimador MAP

El estimador MAP (máximo a posteriori) corresponde a la moda de la distribución posterior. Para la $\text{Beta}(\alpha', \beta')$, se maximiza la posterior, lo que es equivalente a maximizar el logaritmo de la posterior, puesto que esta es una transformación monótona creciente y no altera el máximo:

$$\max_{\theta} p(\theta \mid \mathcal{D}_n) = \max_{\theta} \ln[p(\theta \mid \mathcal{D}_n)]$$

Aplicando la condición de primer orden:

$$\frac{\Gamma(\alpha'+\beta')}{\Gamma(\alpha')\,\Gamma(\beta')} \cdot \left[\frac{\partial}{\partial\theta}\Big(\ln[\theta^{\alpha'-1}]\Big) + \frac{\partial}{\partial\theta}\Big(\ln[(1-\theta)^{\beta'-1}]\Big)\right] = 0$$
$$\frac{\alpha'-1}{\theta} - \frac{\beta'-1}{1-\theta} = 0$$

de donde se obtiene directamente:

$$\hat{\theta}_{\text{MAP}} = \frac{\alpha'-1}{\alpha'+\beta'-2} = \frac{\alpha+s-1}{\alpha+\beta+n-2}. \tag{4}$$

Para obtener la moda del prior, este calcula resolviendo el siguiente problema de maximización:

$$\max_{\theta} p(\theta) = \max_{\theta} \ln[p(\theta)]$$

Como el prior es $p(\theta) \sim \text{Beta}(\alpha, \beta)$, el proceso de maximización es análogo al cálculo del MAP. Entonces, la moda del prior es:

$$\hat{\theta}_{\text{prior}} = \frac{\alpha-1}{\alpha+\beta-2}$$

Recordando que $\hat{\theta}_{\text{MLE}} = s/n$, es posible reescribir la expresión del MAP (4) como una combinación convexa entre el MLE y la moda del prior:

$$\hat{\theta}_{\text{MAP}} = \frac{n}{\alpha+\beta+n-2} \cdot \frac{s}{n} + \frac{\alpha+\beta-2}{\alpha+\beta+n-2} \cdot \frac{\alpha-1}{\alpha+\beta-2}$$

Donde, se puede definir $\lambda = \frac{n}{\alpha+\beta+n-2} \in (0,1)$, entonces:

$$\hat{\theta}_{\text{MAP}} = \lambda\,\hat{\theta}_{\text{MLE}} + (1-\lambda)\,\hat{\theta}_{\text{prior}}$$

De esta forma, el peso λ refleja la contribución relativa de los datos: a mayor n, más domina el MLE y menor es la influencia del prior.

- **Caso $\alpha = \beta = 1$ - prior uniforme:**

  Bajo el prior uniforme Beta$(1,1)$, el MAP se reduce a:

  $$\hat{\theta}_{\text{MAP}}\big|_{\alpha=\beta=1} = \frac{s+1-1}{n+2-2} = \frac{s}{n} = \hat{\theta}_{\text{MLE}}$$

  En este caso, el MAP y el MLE coinciden exactamente, por lo tanto, esto es consistente con el hecho de que el prior uniforme no aporta información sobre θ, por lo que maximizar la posterior equivale a maximizar únicamente la verosimilitud.

- **Caso $\alpha, \beta < 1$:**

  Cuando $\alpha, \beta < 1$, la distribución Beta(α, β) es bimodal, con masa concentrada en los extremos $\theta = 0$ y $\theta = 1$. En este régimen, la fórmula del MAP (4) arroja un valor negativo o mayor que 1, lo que carece de interpretación como probabilidad. Formalmente, la posterior deja de ser unimodal y el MAP no corresponde a un único máximo interior en $(0,1)$: dependiendo de los datos, el máximo global de la posterior puede ubicarse en uno de los extremos del intervalo. Por lo tanto, el estimador MAP no siempre está bien definido como un valor en el interior de $(0,1)$.

1.4. Evolución de la distribución posterior y consistencia bayesiana en el modelo Beta-Bernoulli

1.4.1. Evolución de la Posterior

La Figura 5 muestra la evolución de $p(\theta \mid \mathcal{D}_k)$ para los cuatro priors y $k \in \{1, 5, 10, 25, 50, 100, 500, 1000\}$, mientras que la Figura 6 muestra la evolución continua de la media posterior, el MAP y el MLE junto al intervalo de credibilidad del 95%. Ambos gráficos se presentan en el Anexo 2.8. De ambos gráficos se observa un patrón común: independientemente del prior, la posterior se concentra en torno a $\theta_{\text{true}} = 0.7$ y reduce su varianza conforme crece k, manifestando la consistencia bayesiana.

- **Prior uniforme Beta(1,1):** Al no imponer ninguna creencia, la posterior se forma íntegramente desde los datos, por lo que MAP y MLE coinciden para todo k. El IC es amplio para k pequeño y se estrecha progresivamente, reflejando la reducción de incertidumbre epistémica.

- **Prior optimista Beta(5,1):** Al estar alineado con $\theta_{\text{true}} = 0.7$, es el que converge más rápidamente: prior y verosimilitud apuntan en la misma dirección, manteniendo la media posterior cercana a 0.7 desde las primeras observaciones, mientras el MLE fluctúa considerablemente. Esto evidencia la ventaja del enfoque bayesiano cuando el prior está bien calibrado.

- **Prior pesimista Beta(1,5):** Es el caso de convergencia más lenta, pues la verosimilitud debe acumular suficiente evidencia para corregir el sesgo inicial hacia $\theta \approx 0$. Ilustra el riesgo de un prior fuerte y mal especificado: retarda significativamente la convergencia hacia θ_{true}.

- **Prior concentrado Beta(10,10):** La posterior parte anclada en 0.5 y converge gradualmente hacia θ_{true}, con un comportamiento intermedio entre el prior optimista y el pesimista.

A partir de $k \approx 100$, las cuatro posteriores son prácticamente indistinguibles, punto en que $n \gg \alpha+\beta$ para todos los casos y el peso relativo del prior $(\alpha+\beta)/(\alpha+\beta+n)$ se vuelve despreciable. Respecto a la convergencia del MAP y la media posterior, ambos convergen al mismo valor asintótico, siendo la discrepancia visible únicamente con pocos datos, donde la asimetría de la posterior hace que media y moda difieran.

1.5. Incertidumbre aleatoria y epistémica y su impacto en la predicción bayesiana

1.6. Incertidumbre Aleatoria y Epistémica

- La incertidumbre epistémica refleja la ignorancia sobre el valor del parámetro θ, y está representada por la distribución posterior $p(\theta \mid \mathcal{D}_k)$. Esta incertidumbre sí puede reducirse acumulando más observaciones: como se observa en los gráficos anteriores, independientemente del prior elegido, la posterior se concentra progresivamente en torno a $\theta_{\text{true}} = 0.7$ y su varianza disminuye conforme crece k, reflejando que el modelo aprende sobre θ a partir de los datos.

- La incertidumbre aleatoria es inherente al proceso generador de datos (en este caso, el lanzamiento de una moneda) y no puede reducirse con más observaciones. Incluso conociendo exactamente θ, cada lanzamiento individual sigue siendo impredecible: se puede estimar con alta precisión la proporción de caras esperada en n lanzamientos, pero el resultado de cada lanzamiento particular permanece incierto. Esta irreducibilidad se manifiesta en los gráficos: aun para $k = 1000$, el intervalo de credibilidad no colapsa a un punto, pues siempre subsiste la variabilidad propia del proceso aleatorio.

- Predicción plug-in vs. distribución predictiva bayesiana:

  La predicción plug-in utiliza directamente el MLE como si fuera el valor verdadero del parámetro:

  $$\mathbb{P}_{\text{plug-in}}(X_{n+1} = 1) = \hat{\theta}_{\text{MLE}} = \frac{s}{n}$$

  capturando únicamente la incertidumbre aleatoria del proceso, pero ignorando por completo la incertidumbre epistémica sobre θ. En contraste, la distribución predictiva bayesiana marginaliza sobre todos los valores posibles de θ, ponderados por la posterior:

  $$\mathbb{P}(X_{n+1} = 1 \mid \mathcal{D}_n) = \int_0^1 \theta\, p(\theta \mid \mathcal{D}_n)\, d\theta = \frac{\alpha + s}{\alpha + \beta + n}$$

  incorporando así ambas fuentes de incertidumbre. Con pocos datos, ambas predicciones difieren considerablemente, pues la incertidumbre epistémica es alta y el MLE es inestable. A medida que $n \to \infty$, la incertidumbre epistémica se reduce y ambas predicciones convergen, pues $(\alpha + s)/(\alpha + \beta + n) \to s/n = \hat{\theta}_{\text{MLE}}$.

2. Regresión no lineal y MLE

2.1. Análisis exploratorio y selección de granularidad en series temporales

La Figura 1 muestra el conteo de reseñas del dataset *Amazon Reviews 2023* agregado a frecuencia diaria y semanal.

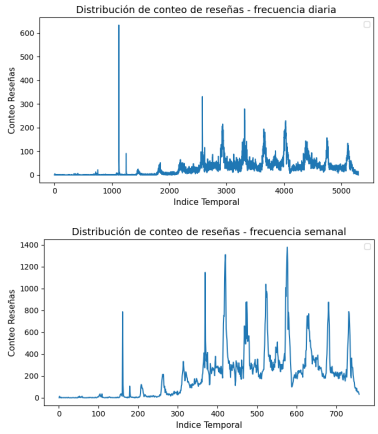

Figure 1. Distribución de conteo de reseñas

Se selecciona la granularidad semanal pues, a diferencia de la diaria, suaviza las fluctuaciones de corto plazo (incluyendo un valor atípico de magnitud aproximada 600 cerca del índice 1000), permitiendo identificar con mayor nitidez una tendencia creciente de largo plazo y un patrón de estacionalidad de amplitud variable. Respecto a la granularidad mensual, la semanal provee aproximadamente 4 veces más observaciones (757 vs. 174), favoreciendo la estimación de parámetros sin sacrificar la relación señal-ruido.

El dataset se particiona destinando el 75% de los datos al conjunto de entrenamiento (primeros datos cronológicamente) y el 25% restante al conjunto de test, cuyos conteos se presentan en la Figura 2.

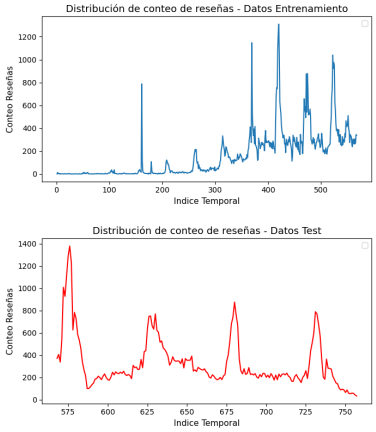

Figure 2. Distribución de conteo de reseñas en train y test

En el conjunto de entrenamiento se observa una tendencia creciente de largo plazo, acompañada de un patrón estacional con peaks aproximadamente cada 50 semanas seguidos de descensos abruptos, y con amplitud variable entre ciclos. En el conjunto de test, en cambio, la tendencia se invierte, tornándose decreciente, y manteniéndose el patrón estacional de período similar, aunque con amplitudes más homogéneas entre peaks.

2.2. Ajuste y evaluación de modelos de regresión polinomial

Utilizando `np.polyfit` con los datos de entrenamiento, se ajustaron modelos polinomiales de grado 1 a 5, cuyos resultados se presentan en la Figura 3:

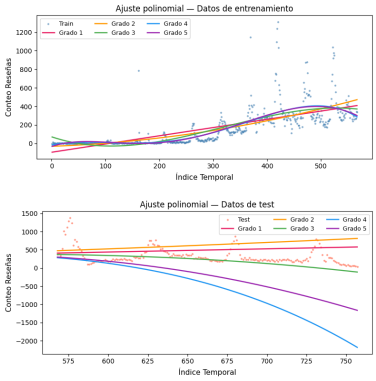

Figure 3. Ajuste polinomial en train y test

En el conjunto de entrenamiento, todos los grados capturan razonablemente la tendencia creciente de largo plazo, pero ninguno logra capturar las estacionalidades ni las amplitudes de los peaks. Al evaluar sobre el test, el desempeño se deteriora significativamente: los polinomios de mayor grado exageran la tendencia decreciente, produciendo predicciones negativas carentes de sentido para datos de conteo.

2.3. Evaluación y selección de modelos de regresión polinomial mediante métricas de desempeño

Para el cálculo de las métricas se utilizó la librería scikit-learn. Los resultados se presentan en la Tabla 1:

Grado	ECM Tr	ECM Te	EAM Tr	EAM Te	R^2 Tr	R^2 Te
1	20934.82	8.98×10^4	87.55	261.66	0.503	-0.698
2	20123.64	1.72×10^5	78.26	369.55	0.522	-2.241
3	18651.79	6.87×10^4	75.92	184.78	0.557	-0.298
4	17813.76	1.32×10^6	67.57	938.14	0.577	-23.994
5	17790.97	5.33×10^5	68.47	610.15	0.577	-9.064

Grado	MSLE Tr	MSLE Te
1	1.781	0.795
2	1.383	1.187
3	1.867	4.248
4	0.924	23.438
5	1.211	20.397

Table 1. Comparación de métricas para regresión polinomial

En el conjunto de entrenamiento, a medida que aumenta el grado del polinomio las métricas de error disminuyen progresivamente, siendo el grado 5 el de menor ECM y EAM. El coeficiente R^2 se mantiene en torno a 0.5 para todos los grados, indicando que los modelos explican aproximadamente el 50% de la variabilidad de los datos, lo cual es esperable dado que ningún polinomio logra capturar la estacionalidad ni los peaks de la serie. El ECM elevado es consistente con la presencia de valores atípicos asociados a dichos peaks.

En el conjunto de test, el comportamiento se deteriora drásticamente. El ECM alcanza magnitudes excesivamente grandes para grados altos, el R^2 es negativo en todos los casos, indicando que el modelo predice peor que simplemente usar la media, y el MSLE se dispara para grados 4 y 5, consecuencia directa de las predicciones negativas que estos polinomios generan al extrapolar fuera del rango de entrenamiento, como se observaba en la Figura 3.

Lo anterior evidencia un claro problema de overfitting: los polinomios de mayor grado aprenden la variabilidad del train pero no generalizan al test. Considerando el balance entre ambos conjuntos, el polinomio de grado 3 es el más adecuado, pues presenta métricas de error aceptables en train y las más bajas en test, siendo el único que mantiene el ECM y el MSLE en magnitudes razonables en ambos conjuntos simultáneamente.

2.4. Demostración MLE es equivalente a MCO para el modelo Gausseano

Dado que el mejor polinomio encontrado fue de grado 3, el modelo probabilístico se formula como:

$$y_i = \underbrace{\beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3}_{f_\theta(x_i)} + \eta, \qquad \eta \sim \mathcal{N}(0, \sigma^2)$$

donde $\theta = (\beta_0, \beta_1, \beta_2, \beta_3)^\top$ es el vector de parámetros a estimar. Dado que η es gaussiano y $f_\theta(x_i)$ es determinista, se tiene que:

$$y_i \mid x_i, \theta \sim \mathcal{N}(f_\theta(x_i),\, \sigma^2)$$

Recordando que la densidad gaussiana está dada por $\mathcal{N}(y; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(\frac{-(y-\mu)^2}{2\sigma^2}\right)$. La verosimilitud conjunta bajo independencia es:

$$\begin{aligned} p(y \mid x, \theta) &= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - f_\theta(x_i))^2}{2\sigma^2}\right) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{\sum_{i=1}^{n}(y_i - f_\theta(x_i))^2}{2\sigma^2}\right) \end{aligned}$$

Tomando logaritmo y eliminando los términos constantes respecto a θ, la log-verosimilitud es:

$$\ell(\theta) = \log p(y \mid x, \theta) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - f_\theta(x_i))^2 \tag{5}$$

Maximizando la log-verosimilitud:

$$\max_\theta \ell(\theta) = \max_\theta \left[-\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - f_\theta(x_i))^2\right]$$

Como $-n/2\,\log(2\pi\sigma^2)$ no depende de θ y $-1/2\sigma^2 < 0$, maximizar $\ell(\theta)$ respecto a θ es equivalente a minimizar la suma de errores cuadráticos:

$$\hat{\theta}^{\text{MLE}} = \arg\max_\theta\ \ell(\theta) = \arg\min_\theta \sum_{i=1}^{n}(y_i - f_\theta(x_i))^2 = \hat{\theta}^{\text{MCO}}$$

Por lo tanto, bajo el supuesto de ruido gaussiano, el estimador de máxima verosimilitud coincide exactamente con el estimador de mínimos cuadrados ordinarios.

2.5. Estimación por máxima verosimilitud en un modelo no lineal y extensión con componentes sinusoidales

Considerando que el mejor polinomio fue de grado 3, se considerará el siguiente modelo:

$$y_i = \underbrace{x_i + x_i^2 + x_i^3 + \theta_1 \sin(\theta_2 x_i + \theta_3) e^{\theta_4 x_i}}_{f_\theta(x_i)} + \eta, \qquad \eta \sim \mathcal{N}(0, \sigma^2)$$

Como η es gaussiano y $f_\theta(x_i)$ es deterministas, se tiene lo siguiente:

$$y_i \mid x_i, \theta \sim \mathcal{N}(f_\theta(x_i),\, \sigma^2)$$

Por lo tanto, la verosimilitud conjunta bajo el supuesto de independecia, viene dada por:

$$\begin{aligned} p(y \mid x, \theta) &= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - f_\theta(x_i))^2}{2\sigma^2}\right) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{\sum_{i=1}^{n}(y_i - f_\theta(x_i))^2}{2\sigma^2}\right) \end{aligned}$$

Con $f_\theta(x_i) = x_i + x_i^2 + x_i^3 + \theta_1 \sin(\theta_2 x_i + \theta_3) e^{\theta_4 x_i}$

Notar que claramente, la función anterior no es lineal en los parámetros $\theta = (\theta_1, \theta_2, \theta_3, \theta_4)$, por lo que, no existe solución análitica al problema de máximización, y se debe calcular de forma númerica, además, es bien probable que los parametros no convergan. Se tienen los siguientes valores inciales de los parametros θ:

Init	$\theta_1^{(0)}$	$\theta_2^{(0)}$	$\theta_3^{(0)}$	$\theta_4^{(0)}$	Descripción
1	1.0	1.0	0.0	0.01	Sugerida por enunciado
2	10.0	0.05	1.0	0.01	Amplitud alta
3	1.0	1.0	0.0	0.01	Frecuencia alta
4	0.1	0.01	0.0	0.01	Amplitud baja
5	-1.0	0.1	π	0.01	Amplitud negativa
6	20.0	0.01	0.0	0.01	Frecuencia muy baja
7	1.0	1.0	1.0	50.0	θ_4 muy grande
8	0.1	0.01	0.01	0.1	Frecuencia alta y amplitud baja
9	0.1	0.01	1.0	-0.5	Amortiguamiento negativo
10	-1.0	-1.0	-1.0	-1.0	Todos negativos

Init	$\hat{\theta}_1$	$\hat{\theta}_2$	$\hat{\theta}_3$	$\hat{\theta}_4$	ECM Te	Conv.
1	-824.00	12.55	-9.49	-0.105	6.87×10^4	No
2	1068.83	-0.41	0.23	-1.077	6.87×10^4	No
3	-824.00	12.55	-9.49	-0.105	6.87×10^4	No
4	54.71	-6.26	5.12	-0.000	6.49×10^4	No
5	-281.30	-0.86	3.23	-1.196	6.87×10^4	No
6	1337.90	0.32	-3.35	-0.972	6.87×10^4	No
7	1.00	1.00	1.00	50.000	∞	No
8	-54.71	0.02	1.97	-0.000	6.49×10^4	No
9	-54.71	-0.02	1.17	-0.000	6.49×10^4	No
10	-4.39	0.06	-5.68	0.005	6.82×10^4	No

Table 2. Análisis de sensibilidad a condiciones iniciales

Ninguna condición inicial convergió según el criterio de BFGS, lo que indica que la superficie de la función objetivo es compleja, con múltiples mínimos locales. Sin embargo, el modelo no es excesivamente sensible a las condiciones iniciales, salvo cuando estas son extremadamente grandes: el caso 7 ($\theta_4 = 50$) ilustra esto claramente, pues la exponencial $e^{\theta_4 x}$ diverge numéricamente, haciendo que el optimizador no avance y el ECM en test sea prácticamente infinito. Para el resto de condiciones iniciales con valores moderados, el ECM en test no varía significativamente.

Los casos 4, 8 y 9 alcanzan el menor ECM Test ($\approx 64{,}897$), lo que sugiere que existe una familia de soluciones con $\hat{\theta}_4 \approx 0$ que produce el mejor ajuste en test. Esto es interpretable: un θ_4 cercano a cero hace que el factor exponencial $e^{\theta_4 x} \approx 1$, reduciendo la componente sinusoidal a una oscilación de amplitud aproximadamente constante, lo cual es más estable para la extrapolación al conjunto de test.

El mejor resultado corresponde al caso 9, con los parámetros y métricas reportados en la Tabla 3.

$\hat{\theta}_1$	$\hat{\theta}_2$	$\hat{\theta}_3$	$\hat{\theta}_4$
-54.706	-0.021	1.168	-0.0003

Conjunto	ECM	EAM	R^2	MSLE
Train	17,472.9	69.2	0.585	1.106
Test	64,897.9	167.5	-0.226	2.557

Table 3. Parámetros óptimos (Init 9) y métricas de desempeño

Respecto al desempeño, la incorporación de la componente sinusoidal mejora marginalmente el ajuste en train respecto al polinomio de grado 3 solo: el R^2 aumenta de 0.557 a 0.585 y las métricas de error disminuyen ligeramente, lo que indica que la oscilación captura algo de la variabilidad no explicada por la tendencia polinomial. Sin embargo, el modelo sigue sin generalizar adecuadamente al conjunto de test: el R^2 negativo (-0.226) indica que el modelo predice peor que simplemente usar la media de los datos, y las métricas de error siguen siendo elevadas, lo que sugiere que una única componente sinusoidal es insuficiente para capturar la estructura oscilatoria compleja de los datos.

2.6. Comparación de métodos de optimización para estimación por máxima verosimilitud en modelos no lineales

Fijando los parámetros $\theta_1, \ldots, \theta_4$ obtenidos en la parte anterior, el modelo con la segunda componente sinusoidal es:

$$y_i = \underbrace{f^{\text{pol-sin}}(x_i) + \theta_5 \sin(\theta_6 x_i + \theta_7) e^{\theta_8 x_i}}_{f_\theta(x_i)} + \eta, \qquad \eta \sim \mathcal{N}(0, \sigma^2),$$

donde $f^{\text{pol-sin}}(x_i) = f^{\text{pol}}(x_i) + \theta_1 \sin(\theta_2 x_i + \theta_3) e^{\theta_4 x_i}$ con $(\hat{\theta}_1, \hat{\theta}_2, \hat{\theta}_3, \hat{\theta}_4) = (-54.706,\, -0.021,\, 1.168,\, -0.0003)$ fijos. La verosimilitud conjunta es análoga a la parte anterior:

$$p(y \mid x, \theta) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{\sum_{i=1}^{n}(y_i - f_\theta(x_i))^2}{2\sigma^2}\right).$$

Al igual que antes, el modelo es no lineal en $(\theta_5, \theta_6, \theta_7, \theta_8)$, por lo que no admite solución cerrada y se recurre a optimización numérica, con el riesgo asociado de convergencia a mínimos locales.

Los resultados para los tres métodos de optimización, usando la condición inicial $\theta_8 = 0.01$, se presentan en la Tabla 4 y de manera visual en la Figura 7.

Método	$\hat{\theta}_5$	$\hat{\theta}_6$	$\hat{\theta}_7$	$\hat{\theta}_8$
BFGS	55.391	-0.113	-0.145	-0.218
N.-Mead	24.812	0.121	-11.441	0.004
L-BFGS-B	13.680	0.178	-3.216	-0.006

Método	ECM Te	EAM Te	R^2 Te	MSLE Te	Iter	Evals	Conv.
BFGS	64897.861	167.479	-0.226	2.557	123	1252	No
N.-Mead	52958.018	175.202	-0.001	5.347	438	791	Sí
L-BFGS-B	64919.636	167.513	-0.227	2.555	7	490	No

Table 4. Comparación de métodos de optimización y desempeño del modelo en test

El modelo optimizado con Nelder-Mead es el que mejor se ajusta en train y test, capturando con mayor fidelidad las oscilaciones y peaks, tal como lo muestra la figura 8, en cuanto a las métricas reportadas, su ECM en test disminuye aproximadamente un 18% respecto a los modelos anteriores. Sin embargo, su EAM es ligeramente superior, pues los valles predichos se alejan más de los valores reales al intensificar la tendencia decreciente del test. BFGS y L-BFGS-B convergen a soluciones prácticamente idénticas entre sí, limitándose a seguir la tendencia polinomial sin capturar la estacionalidad.

En cuanto al proceso de optimización, Nelder-Mead es el único método que convergió formalmente y de acuerdo con Chen (2023), es el único libre de derivadas, pues opera sobre un símplex de $n+1$ vértices mediante reflexión, expansión y contracción, lo que lo hace robusto ante funciones no diferenciables, discontinuas, ruidosas o con múltiples mínimos locales (exactamente el caso de este modelo). En contraste, BFGS y L-BFGS-B aproximan la Hessiana para determinar la dirección de descenso, lo que explica su mayor eficiencia por iteración (L-BFGS-B: 7 iteraciones vs. 438 de Nelder-Mead), pero los hace más susceptibles a quedar atrapados en mínimos locales. El mayor número de evaluaciones de BFGS (1252 vs. 791 de Nelder-Mead) refleja el costo adicional de estimar el gradiente numéricamente en cada iteración.

2.7. Análisis e interpretación del modelo final y comparación de métodos de optimización

- **Rol de cada componente del modelo final.** El polinomio de grado 3 captura la tendencia de largo plazo, modelando el crecimiento sostenido del conteo de reseñas. La primera componente sinusoidal $\theta_1 \sin(\theta_2 x + \theta_3) e^{\theta_4 x}$ refina el ajuste con una oscilación de amplitud variable, aunque su aporte marginal es limitado, debido a que las métricas de la parte 5 son similares a las del polinomio solo, pues no logra capturar la estacionalidad, como se observa en Figura 7 (En Anexos). Es la segunda componente $\theta_5 \sin(\theta_6 x + \theta_7) e^{\theta_8 x}$ la que captura la *estacionalidad*: su incorporación reduce las métricas de error y permite reproducir los peaks y valles periódicos observados en los datos, como se observa en la Figura 8.

- **Optimización simultánea de todos los parámetros.** Teóricamente posible, pero con dos dificultades prácticas importantes. Primero, aumentar la dimensión de 4 a 8 parámetros incrementa la complejidad de la superficie objetivo, multiplicando los mínimos locales y la sensibilidad a condiciones iniciales. Segundo, la interacción entre ambas componentes sinusoidales genera problemas de identificabilidad, es decir, distintas combinaciones de $(\theta_1, \ldots, \theta_4)$ y $(\theta_5, \ldots, \theta_8)$ pueden producir predicciones equivalentes. La estrategia secuencial adoptada reduce la dimensionalidad en cada etapa y mejora el control sobre la convergencia, a costa de no garantizar el óptimo global.

- **Equivalencia entre MLE y MCO en modelos no lineales.** Como se demostró en la parte 4, bajo ruido gaussiano i.i.d. la equivalencia entre maximizar la verosimilitud y minimizar el ECM es algebraica y se mantiene independientemente de la forma funcional de f_θ. Sin embargo, esta equivalencia puede romperse *operacionalmente* en modelos no lineales: al no existir solución cerrada, ambos criterios se resuelven mediante optimización iterativa sobre una superficie con múltiples mínimos locales, por lo que distintos algoritmos o condiciones iniciales pueden converger a óptimos distintos, no porque los criterios difieran, sino porque ninguno alcanzó el óptimo global. Esto se evidencia en la Tabla 5: a medida que se incorporan componentes al modelo, tanto la NLL como el ECM mejoran consistentemente en train y test, confirmando que en este caso ambos criterios están alineados.

Modelo	NLL Tr	ECM Tr	R^2 Tr	NLL Te	ECM Te
Polinomio g.3	3592.391	18651.787	0.557	1327.608	68661.481
Pol + Sin1	3573.881	17472.890	0.585	1322.253	64897.861
Pol + Sin1 + Sin2	3493.057	13138.625	0.688	1302.938	52958.018

Modelo	R^2 Te	MSLE Te
Polinomio g.3	-0.298	4.248
Pol + Sin1	-0.226	2.557
Pol + Sin1 + Sin2	-0.001	5.347

Table 5. Comparación de desempeño entre modelos

- **Comparación de métodos de optimización.** BFGS y L-BFGS-B son métodos basados en gradiente que aproximan la matriz Hessiana para determinar la dirección de descenso: eficientes por iteración, pero sensibles a mínimos locales en superficies complejas. Nelder-Mead es libre de derivadas, pues opera sobre un símplex de $n+1$ vértices mediante reflexión, expansión y contracción, lo que lo hace más robusto ante funciones no diferenciables o con múltiples mínimos locales, a costa de más evaluaciones de función. En general, los métodos basados en gradiente son preferibles cuando la función objetivo es suave y el gradiente es confiable; Nelder-Mead es preferible cuando estas

condiciones no se cumplen, como ocurre en este modelo.

2.8. Análisis crítico del modelo: validación de supuestos, residuos y limitaciones

- **EMV de σ_n^2 y análisis de heterocedasticidad.** Dado que la log-verosimilitud conjunta es la misma obtenida en la parte 4 (ecuación 5), basta con fijar $\hat{\theta}$ y maximizar respecto a σ^2. Aplicando la condición de primer orden:

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^{n} \left(y_i - f_{\hat{\theta}}(x_i)\right)^2 = 0$$

de donde se obtiene directamente:

$$\hat{\sigma}^2_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^{n} \left(y_i - f_{\hat{\theta}}(x_i)\right)^2 = \frac{1}{n} \sum_{i=1}^{n} r_i^2$$

es decir, el estimador que maximiza la verosimilitud con respecto a la varianza es el promedio de los residuos al cuadrado.

La Figura 4 presenta los residuos en función del tiempo y de los valores predichos, para train y test.

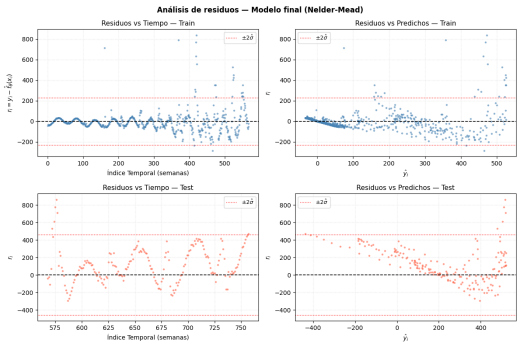

Figure 4. Análisis de residuos — Modelo final (Nelder-Mead)

Del gráfico se observa evidencia clara de heterocedasticidad. En train, los residuos vs. tiempo muestran dispersión creciente hacia el final del período, con valores que superan la banda $\pm 2\hat{\sigma}$, mientras que los residuos vs. predichos evidencian mayor varianza para valores intermedios de $\hat{y}_i$, sugiriendo que la varianza depende del nivel de la serie. En test, la heterocedasticidad es aún más pronunciada: los residuos exhiben oscilaciones de gran amplitud asociadas a los peaks, con dispersión irregular en el gráfico vs. predichos. En conjunto, ambos gráficos permiten rechazar la hipótesis de varianza constante, invalidando el supuesto homocedástico del modelo.

- **Supuesto de ruido gaussiano: limitaciones y alternativas.** El supuesto gaussiano no es razonable por dos razones. Primero, el dominio de la distribución gaussiana es $(-\infty, +\infty)$, permitiendo predicciones negativas carentes de interpretación y sentido para datos de conteo, como se observa en la Figura 7, donde las predicciones en test toman valores negativos. Segundo, el supuesto de varianza constante no se cumple, pues como se evidenció en el análisis de residuos, el modelo presenta heterocedasticidad. Una alternativa más apropiada es la distribución Poisson, que restringe las predicciones a enteros no negativos y cuya propiedad $\text{Var}(Y) = \mathbb{E}[Y] = \lambda$ captura naturalmente que períodos con más reseñas presentan mayor variabilidad. Si la varianza empírica supera a la media (sobredispersión), la distribución binomial negativa sería aún más adecuada al modelar varianza y media de forma independiente.

- **Quiebres estructurales y fallas sistemáticas.** Del análisis de residuos se identifica que, a partir de la semana ≈ 400, el modelo comienza a fallar de forma sistemática: los residuos aumentan en magnitud y dispersión, asociados a los peaks de gran amplitud observados en la serie. Estos peaks podrían explicarse por eventos externos como fechas de alto consumo (como Cyber Day), donde un aumento repentino en ventas genera posteriormente un alza en reseñas, seguida de una caída abrupta. El modelo no incorpora ningún mecanismo para detectar ni adaptarse a estos quiebres estructurales: al minimizar el ECM, los valores extremos reciben mayor penalización al cuadrado, lo que distorsiona el ajuste global atrayendo los parámetros hacia esos puntos y deteriorando el ajuste en el resto de la serie. Adicionalmente, el modelo es entrenado sobre una tendencia creciente (train) pero evaluado sobre una tendencia decreciente (test), lo que constituye un quiebre estructural que el modelo no puede anticipar, resultando en predicciones sistemáticamente sesgadas en el conjunto de test.

- **Incorporación de incertidumbre epistémica mediante el enfoque bayesiano.** El modelo actual entrega una predicción puntual $\hat{f}_\theta(x)$ basada en el MLE, ignorando la incertidumbre sobre θ. El enfoque bayesiano incorporaría esta incertidumbre colocando un prior $p(\theta)$ y obteniendo la posterior $p(\theta \mid \mathcal{D})$, para luego marginalizar sobre todos los valores posibles de θ y obtener una distribución completa sobre las predicciones futuras. Las bandas de credibilidad se obtienen directamente como cuantiles de esta distribución predictiva, produciendo bandas más amplias en regiones de mayor incertidumbre, como los períodos de peaks o quiebres estructurales identificados anteriormente, capturando de forma más honesta la incertidumbre total de las predicciones que una simple predicción plug-in.

Referencias

Chen, E. (2023, April 8). The simplex approach of the Nelder-Mead algorithm. Medium. https://medium.com/@ethanwchen/the-simplex-approach-of-the-nelder-mead-algorithm-c582556d8d84

McAuley Lab. (2024). Amazon Reviews 2023. Amazon Reviews 2023 dataset. https://amazon-reviews-2023.github.io/main.html

Apéndice

Evolución completa de la posterior

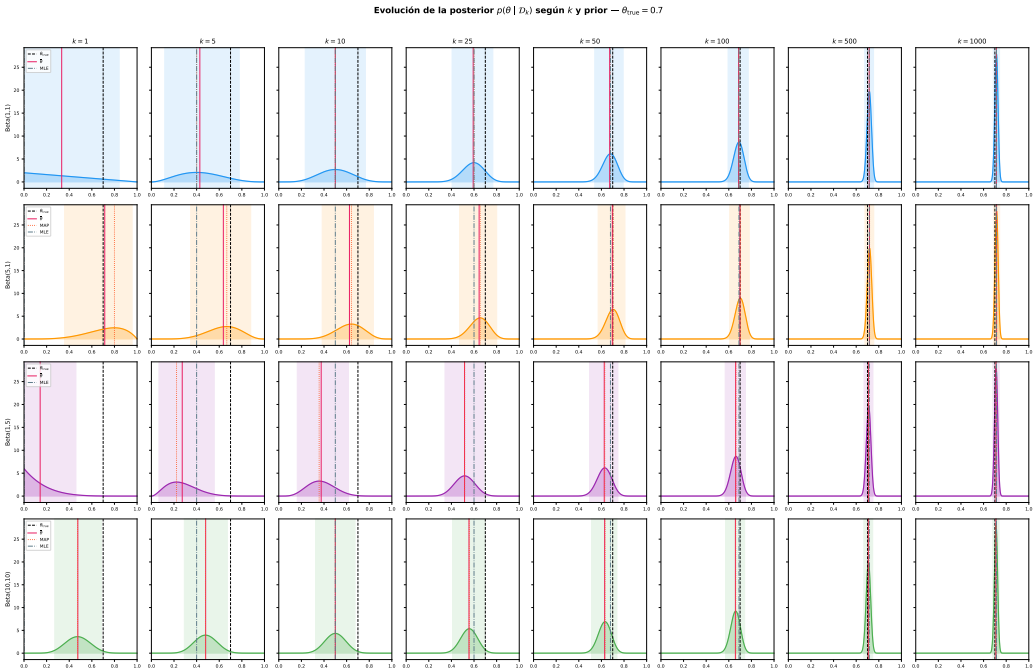

Figure 5. Evolución de $p(\theta \mid \mathcal{D}_k)$ para $k \in \{1, 5, 10, 25, 50, 100, 500, 1000\}$ y los cuatro priors considerados.

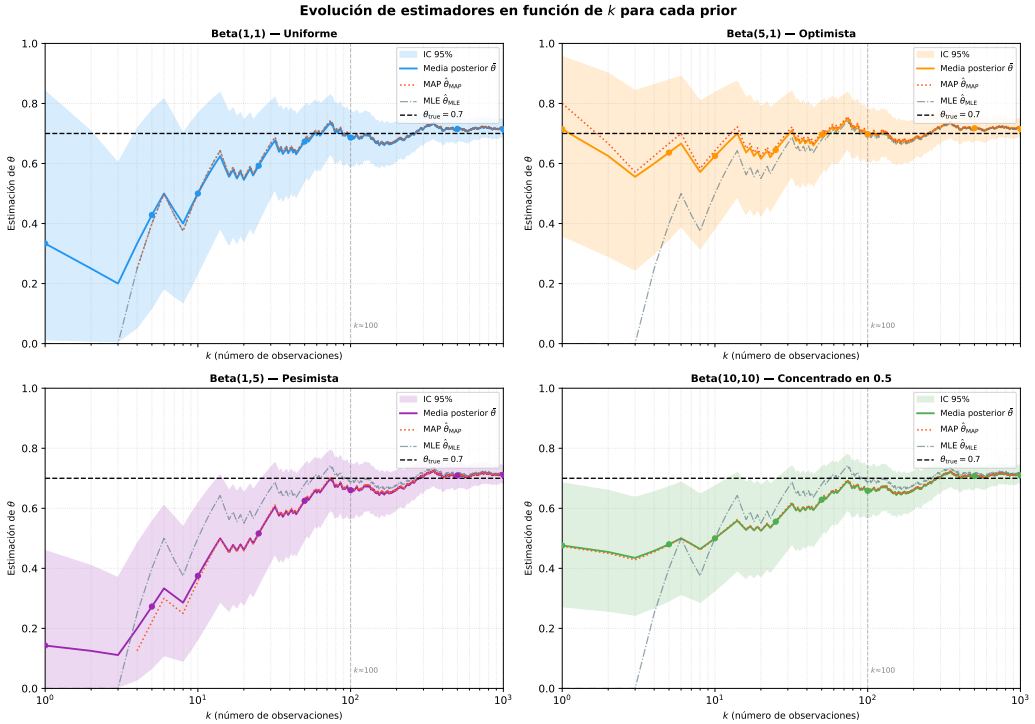

Figure 6. Evolución de los estimadores para $k \in \{1, 5, 10, 25, 50, 100, 500, 1000\}$ y los cuatro priors considerados.

Distribución del modelo polinomial + componente sinusoidal evaluado en Test y Train

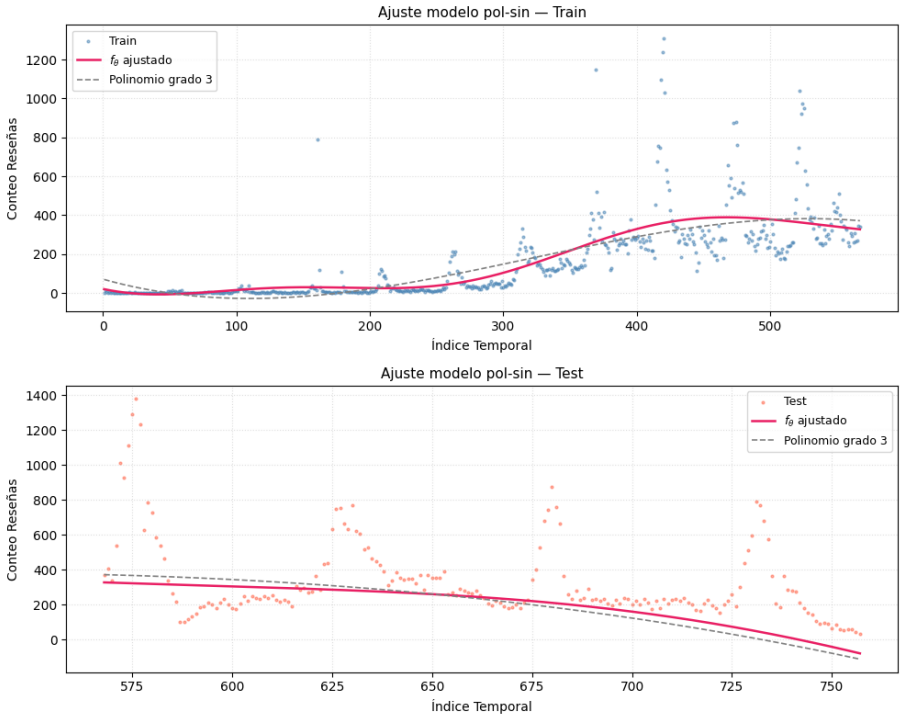

Figure 7. Evaluación del módelo polinomial más primera componente sinuosoidal en Train y Test para los métodos de optimización

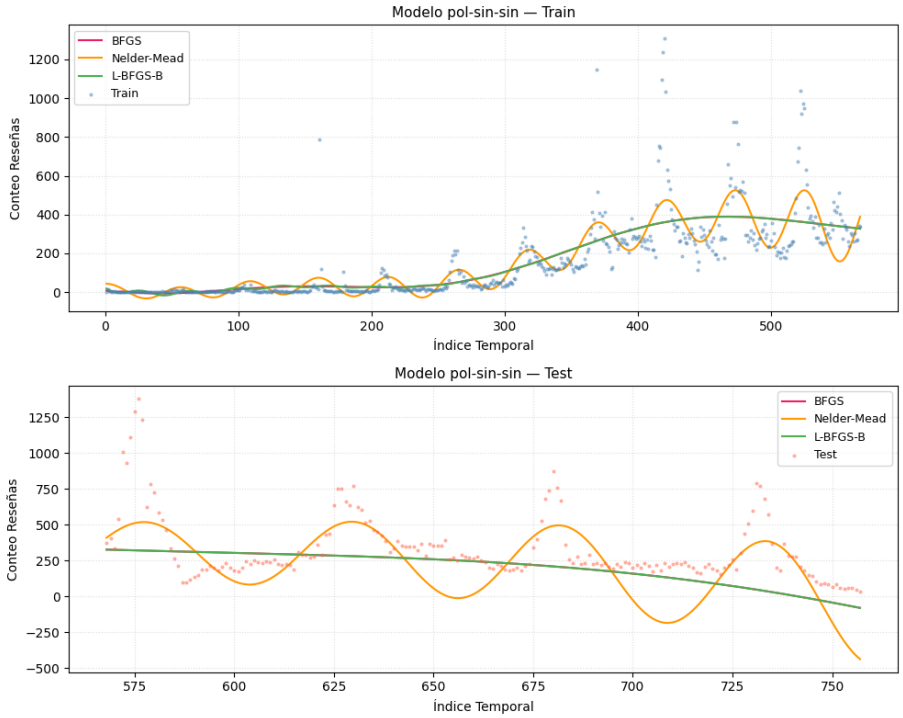

Figure 8. Evaluación del módelo con segunda componente sinusoidal en Train y Test para los métodos de optimización