

Tarea 3

Fecha de entrega: 11 de mayo de 2026, 23.59hrs.

Profesor: Francisco Vásquez L.

Auxiliares: Álvaro Márquez, Diego Olguín Wende.

Ayudantes: Tamara Carrasco, Javiera Yáñez.

Formato de entrega	PDF con extensión máxima de 8 páginas, con anexos (no cuentan en la cantidad de páginas), con doble columna, abstract, título e integrante y referencias. Si hace su reporte en $\text{\LaTeX}$, utilice el template de la conferencia ICML disponible en este enlace , o bien uno de formato similar. Adicionalmente debe entregar el <i>jupyter notebook</i> (o el código que haya generado) con la resolución de la tarea y debe fijar semillas antes de los procesos aleatorios. El código en sí no será evaluado.
Recomendación	Presente y analice sus resultados, detallando la metodología utilizada. Incorpore gráficos para apoyar su análisis.
Criterios de evaluación	La tarea será evaluada en base a la claridad de la metodología y las explicaciones, la profundidad de la reflexión en las preguntas conceptuales, el desarrollo teórico y el dominio que el/la estudiante demuestre de la conexión entre la teoría y la aplicación.
Carácter de la tarea	Individual.

Heart Failure Prediction: Validación, Hiperparámetros y Comparación de Modelos

A lo largo de esta tarea trabajará con la base de datos “Heart Failure Prediction” del archivo `heart.csv`, donde la variable objetivo es `HeartDisease`¹. Utilice **todas** las variables disponibles, incluyendo `ChestPainType`.

Convenciones para toda la tarea: (i) clase positiva `HeartDisease=1`; (ii) genere variables *dummies*² con `drop_first=True` (o equivalente) para evitar colinealidad perfecta; (iii) para modelos sin probabilidad nativa (*e.g.*, Perceptrón) use `decision_function` en lugar de `predict_proba`; (iv) fije una semilla común y repórtela. Cuando se solicite “reportar métricas”, considere el conjunto $\mathcal{M} = \{\text{Accuracy, Precision, Recall, Specificity, F1-Score, FPR, FNR}\}$.

- (a) **Marco teórico.** Explique brevemente en qué consisten los enfoques discriminativo y generativo, indicando qué distribución modela cada uno (*i.e.*, $P(Y | X)$ vs. $P(X | Y)$ y $P(Y)$). En clase se mostró que, bajo el supuesto generativo gaussiano con covarianza compartida ($p(x | \mathcal{C}_k) = \mathcal{N}(x; \mu_k, \Sigma)$, $\pi_k = \mathbb{P}(\mathcal{C}_k)$), el log-posterior es *afín* en x y la probabilidad a posteriori adopta exactamente la forma logística

$$\mathbb{P}(\mathcal{C}_1 | x) = \sigma(a^\top x + b), \quad a = \Sigma^{-1}(\mu_1 - \mu_2), \quad b = -\frac{1}{2}(\mu_1 + \mu_2)^\top a + \ln \frac{\pi_1}{\pi_2}.$$

¹ <https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>

² https://pandas.pydata.org/docs/reference/api/pandas.get_dummies.html

Es decir, **LDA y Regresión Logística comparten la misma familia de fronteras** (lineales en x), pero difieren en **cómo** se estiman los parámetros (a, b) :

- **Generativo (LDA)**: estimar $\theta = \{\pi, \mu_1, \mu_2, \Sigma\}$ por máxima verosimilitud sobre la densidad conjunta $p(x, t | \theta)$, y *derivar* (a, b) analíticamente a partir de θ .
- **Discriminativo (Regresión Logística)**: estimar (a, b) *directamente* maximizando la verosimilitud condicional $p(t | x; a, b)$, sin modelar $p(x)$.

Discuta: (i) ¿qué se optimiza en cada caso y qué supuestos subyacen?, (ii) ¿por qué la regresión logística es estrictamente discriminativa (y no admite, por sí sola, una versión generativa) aunque comparta su forma funcional con LDA?, y (iii) ¿en qué situaciones cabría esperar que cada vía produzca mejores estimaciones de (a, b) ?

- (b) **Particionamiento y exploración.** Separe los datos en entrenamiento (80 %) y test (20 %) con `train_test_split` (`sklearn.model_selection`), usando `stratify` apropiadamente. Esta partición será la referencia base para las partes posteriores, salvo indicación contraria. Reporte estadísticas descriptivas para ambos conjuntos: proporción de clases de `HeartDisease`, y media y desviación estándar de `Cholesterol` y `Age`. Compare la distribución de `Cholesterol` entre ambos conjuntos (histograma y/o cuantiles). Comente la importancia de estratificar.
- (c) **Regresión Logística baseline.** Implemente un modelo de Regresión Logística con `sklearn` usando hiperparámetros por defecto. Reporte la matriz de confusión y las métricas $\mathcal{M}$ en entrenamiento y test. Interprete los resultados desde la doble óptica vista en clase: ¿qué le dice cada métrica desde el punto de vista discriminativo (frontera de decisión) y desde el generativo (probabilidades a posteriori implícitas)? Reflexione sobre la asimetría de costos entre un FN (no detectar enfermedad) y un FP en el contexto clínico.
- (d) **Sensibilidad al tamaño de entrenamiento.** Repita la partición y el ajuste con 60 % de entrenamiento y 40 % de test. ¿Cambiaron sus resultados? ¿Qué métricas son más sensibles? Justifique relacionando lo observado con el dilema sesgo-varianza: al reducir el conjunto de entrenamiento, ¿qué espera que ocurra con la varianza de las estimaciones?
- (e) **Curva ROC y AUC.** Explique brevemente qué información entrega la curva ROC³ (TPR vs. FPR) y el AUC⁴ en clasificación binaria. Grafique la curva ROC y reporte el AUC del modelo baseline para las dos divisiones (80/20 y 60/40). Compare: ¿cuál división produce un AUC más estable y por qué?
- (f) **Hiperparámetros de Regresión Logística.** A partir de la documentación de `LogisticRegression` de `sklearn.linear_model`, explique el rol de `penalty`, `C` y `class_weight`. Asocie cada uno con el problema que aborda: `penalty` con el tipo de regularización (sparsity vs. encogimiento), `C` con la *intensidad* de la regularización ($C = 1/\lambda$, por lo que valores pequeños implican mayor regularización), y `class_weight` con el desbalance de clases en la verosimilitud.
- (g) **GridSearchCV.** Sobre la partición 80/20 de (b), realice Validación Cruzada con $K = 5$ dentro del conjunto de entrenamiento, considerando todas las combinaciones de:
- `penalty`: {'l1', 'l2', 'elasticnet'},
 - `C`: {0.1, 1, 10},

³ https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_curve.html

⁴ https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_auc_score.html

- `class_weight`: {'balanced', None, {0:1, 1:5}}.

Se recomienda usar `GridSearchCV` de `sklearn.model_selection` o equivalente. Reporte una tabla con AUC, Accuracy y F1-Score por combinación.

Nota técnica: `penalty='elasticnet'` solo es compatible con `solver='saga'` y requiere especificar el parámetro `l1_ratio`. Configure ambos para evitar errores ajenos al objetivo conceptual.

- (h) **Magnitud de los coeficientes.** Sin validación cruzada, ajuste los 27 modelos correspondientes a las combinaciones de la parte (g) sobre el 80 % de entrenamiento. Denote por $\hat{\beta}_m \in \mathbb{R}^p$ al vector de coeficientes estimados del modelo $m \in M$, donde $|M| = 27$ y p es el número de variables tras la generación de dummies. Defina el conjunto de magnitudes

$$\hat{\beta}_M := \left\{ \|\hat{\beta}_m\|_2 \right\}_{m \in M},$$

es decir, los 27 valores escalares correspondientes a la norma euclidiana del vector de coeficientes de cada modelo. Genere un histograma con los valores de $\hat{\beta}_M$ agrupando o coloreando las barras según el tipo de `penalty`. Discuta cómo la elección de los hiperparámetros (en particular `C` y `penalty`) afecta la magnitud global de los coeficientes. Relacione su análisis con la teoría de regularización vista en clase: ¿qué se espera que ocurra con $\|\hat{\beta}_m\|_2$ cuando $C \rightarrow 0$? ¿Y cuando $C \rightarrow \infty$?

- (i) **Contribución relativa de variables.** Para cada modelo $m \in M$, defina el vector unitario

$$\tilde{\beta}_m := \frac{\hat{\beta}_m}{\|\hat{\beta}_m\|_2} \in \mathbb{R}^p.$$

Cada componente $\tilde{\beta}_{m,j}$ representa la **contribución relativa** de la variable j a la decisión del modelo m , normalizada respecto a la magnitud total de los coeficientes. Responda:

- Para cada modelo m , identifique la variable dominante $j^*(m) = \arg \max_j |\tilde{\beta}_{m,j}|$. Reporte una tabla con los 27 modelos y su variable dominante asociada.
 - ¿Qué variables aparecen con mayor frecuencia como $j^*(m)$? ¿Coincide la variable dominante entre los distintos tipos de `penalty`? Discuta a la luz de las propiedades de L1 (sparsity) y L2 (encogimiento) vistas en clase.
 - Genere un histograma agregado de los valores $|\tilde{\beta}_{m,j}|$ desglosado por tipo de `penalty` (un panel por `penalty`, o un histograma apilado). Discuta la distribución de relevancia entre variables: ¿hay `penalties` que concentran la masa en pocas variables y otros que la distribuyen?
 - ¿Existe alguna combinación de hiperparámetros cuyo $\tilde{\beta}_m$ se comporte de manera atípica respecto al resto? Justifique numéricamente, por ejemplo mediante la distancia coseno respecto a la mediana de los $\tilde{\beta}_m$, o el número de componentes nulos de cada modelo.
- (j) **Mejor combinación de hiperparámetros.** Identifique la mejor combinación según al menos dos métricas (*e.g.*, AUC y F1-Score). ¿Coincide la mejor combinación entre métricas? Si no, ¿qué le sugiere esto sobre el problema (desbalance, costo asimétrico)? Conecte con (h) y (i): ¿la mejor combinación tiene $\|\hat{\beta}\|_2$ pequeño o grande, y concentra o distribuye la importancia entre variables? Interprete los valores específicos de la mejor combinación: por ejemplo, si gana `C=10`, ¿significa poca regularización?, y si gana `class_weight='balanced'`, ¿qué dice esto sobre la distribución de clases?
- (k) **Comparación de clasificadores.** Sobre la misma partición 80/20 de (b), implemente: Perceptrón, Nearest Neighbors, Gaussian Naive Bayes y Linear Discriminant Analysis. Reporte las

métricas de $\mathcal{M}$ en entrenamiento y test, comparándolas con la mejor configuración de Regresión Logística obtenida en (j). Comente los resultados relacionándolos con el enfoque de cada modelo (*discriminativo* vs. *generativo*, paramétrico vs. basado en instancias) y sus limitaciones. ¿Cómo se podrían mejorar?

- (l) **ROC para todos los clasificadores.** Grafique en un mismo plano la curva ROC y reporte el AUC para los cinco modelos de (k). Relacione con el enfoque subyacente: ¿por qué cabe esperar curvas ROC similares entre Regresión Logística y LDA en datos aproximadamente balanceados? ¿Cómo cambia el escenario para GNB y el Perceptrón, dado que asumen estructuras distintas (independencia condicional y separabilidad lineal sin probabilidad, respectivamente)? ¿Qué tipo de modelos tiende a maximizar el AUC y por qué?
- (m) **Subconjuntos de variables.** Considere los siguientes subconjuntos: (i) solo variables categóricas, (ii) solo variables numéricas, y (iii) todas las variables. Reentrene los cinco modelos sobre cada subconjunto (manteniendo la partición 80/20) y calcule AUC, Accuracy y F1-Score. Discuta los resultados: ¿qué subconjunto es más informativo para cada modelo? Comente cómo el enfoque de cada modelo (paramétrico, generativo, basado en distancias) ayuda a explicar por qué ciertos modelos rinden mejor sobre ciertos subconjuntos.
- (n) **Mejor modelo global.** Desde la perspectiva de los supuestos estadísticos de cada modelo y de lo observado en los datos, ¿cuál considera el mejor modelo? Justifique con base en (i) los supuestos respecto a la distribución de los datos, (ii) las métricas observadas, y (iii) la interpretabilidad de los coeficientes o probabilidades a posteriori.