

Tarea 5

Fecha de entrega: 15 de junio de 2026, 23.59hrs.

Profesor: Francisco Vásquez L.

Auxiliares: Álvaro Márquez, Diego Olguín Wende.

Ayudantes: Tamara Carrasco, Javiera Yáñez.

Formato de entrega	PDF con extensión máxima de 8 páginas, con anexos (no cuentan en la cantidad de páginas), con doble columna, abstract, título e integrante y referencias. Si hace su reporte en $\text{\LaTeX}$, utilice el template de la conferencia ICML disponible en este enlace , o bien uno de formato similar. Adicionalmente debe entregar el <i>jupyter notebook</i> (o el código que haya generado) con la resolución de la tarea y debe fijar semillas antes de los procesos aleatorios. El código en sí no será evaluado.
Recomendación	Presente y analice sus resultados, detallando la metodología utilizada. Incorpore gráficos para apoyar su análisis.
Criterios de evaluación	La tarea será evaluada en base a la claridad de la metodología y las explicaciones, la profundidad de la reflexión en las preguntas conceptuales, el desarrollo aplicado y el dominio que el/la estudiante demuestre de la conexión entre los métodos y los resultados obtenidos.
Carácter de la tarea	Individual.

A lo largo de esta tarea continuará trabajando con la base “Heart Failure Prediction” del archivo `heart.csv`, donde la variable objetivo es `HeartDisease`¹. Se asume disponible el preprocesamiento de tareas anteriores y, en particular, la mejor configuración de SVM obtenida en la Tarea 4.

Convenciones para toda la tarea: (i) clase positiva `HeartDisease=1`; (ii) reutilice la misma semilla y la partición 80/20 estratificada empleada en las Tareas 3 y 4, de modo que los resultados sean directamente comparables; (iii) cuando se solicite “reportar métricas”, considere el conjunto $\mathcal{M} = \{\text{Accuracy, Precision, Recall, Specificity, F1-Score, FPR, FNR}\}$; (iv) salvo indicación contraria, los métodos de reducción de dimensionalidad se aplican sobre el conjunto de variables numéricas estandarizadas, ajustando el escalador exclusivamente sobre el conjunto de entrenamiento y transformando luego el conjunto de prueba con dicho ajuste.

P1. Reducción de dimensionalidad lineal y supervisada

Trabaje con las variables numéricas estandarizadas del conjunto de entrenamiento.

- (a) **Análisis de componentes principales.** Ajuste `sklearn.decomposition.PCA` sobre el conjunto de entrenamiento. Recuerde que cada componente principal u_j es un vector propio de la matriz de covarianza muestral $\hat{\Sigma}$ con valor propio asociado λ_j , y que la fracción de varianza explicada por la j -ésima componente corresponde a $\lambda_j / \sum_k \lambda_k$. Reporte los primeros valores propios obtenidos, un

¹ <https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>

gráfico con la varianza explicada por cada componente y la varianza acumulada, e indique cuántas componentes son necesarias para retener al menos el 90 % de la varianza total. A continuación, visualice las dos primeras componentes principales en un gráfico de dispersión, coloreando los puntos según `HeartDisease`, y comente si se observa separación entre clases. Finalmente, inspeccione los vectores propios asociados a las dos primeras componentes y discuta qué variables originales aportan más a cada una; relacione su observación con la interpretación geométrica de PCA como dirección de máxima varianza.

- (b) **Kernel PCA.** A diferencia de PCA estándar, Kernel PCA realiza la descomposición espectral de la matriz de Gram $K_{ij} = k(x_i, x_j)$ centrada, en lugar de la matriz de covarianza, y entrega componentes asociadas a un espacio de características implícito definido por el kernel. Repita la proyección a dos dimensiones utilizando `sklearn.decomposition.KernelPCA` con al menos dos kernels distintos (por ejemplo, `rbf` y `poly`). Acompañe la presentación con gráficos análogos a los de la parte (a) y discuta si la separabilidad visual entre clases se modifica respecto al PCA estándar. Estudie cómo cambia la proyección al variar el parámetro `gamma` en el kernel `rbf` (al menos tres valores) y el grado del polinomio en el kernel `poly` (al menos dos valores). A partir de la forma del kernel `rbf`, $k(x, y) = \exp(-\gamma\|x - y\|^2)$, comente qué tipo de similitudes induce un valor de γ grande frente a uno pequeño y cómo se refleja eso en la proyección.
- (c) **Fisher Discriminant.** Recuerde que el criterio de Fisher consiste en buscar la dirección w que maximiza la razón $J(w) = (w^\top S_B w) / (w^\top S_W w)$, donde S_B es la matriz de dispersión entre clases y S_W la matriz de dispersión intraclase. Ajuste `LinearDiscriminantAnalysis` sobre el conjunto de entrenamiento y obtenga la proyección unidimensional resultante. Explique en pocas líneas, sin entrar en derivaciones, por qué para $K = 2$ clases este procedimiento entrega una sola dirección. Visualice la proyección utilizando un histograma o un gráfico de dispersión unidimensional separado por clase, y discuta si la separación entre clases mejora respecto a la primera componente del PCA obtenido en la parte (a). A la luz de la razón $J(w)$, justifique por qué la proyección de Fisher debería separar mejor las clases que la primera componente principal cuando las direcciones de máxima varianza no coinciden con las direcciones que separan las medias de las clases.

P2. Reducción de dimensionalidad no lineal y sensibilidad a hiperparámetros

Considere los siguientes métodos de reducción no lineal vistos en clases. Isomap aproxima distancias geodésicas sobre la variedad subyacente vía caminos más cortos en un grafo de vecinos más cercanos y luego aplica escalamiento multidimensional sobre esa matriz de distancias. t-SNE define similitudes gaussianas p_{ij} en el espacio original y similitudes t-Student q_{ij} en el espacio reducido, y minimiza la divergencia $D_{KL}(P\|Q)$; la perplejidad determina el ancho de banda gaussiano y, con ello, el número efectivo de vecinos considerados. UMAP construye una representación basada en complejos simpliciales difusos en cada espacio y minimiza la entropía cruzada entre ambas representaciones.

- (a) **Aplicación inicial.** Proyecte el conjunto de entrenamiento a dos dimensiones utilizando los métodos Isomap, t-SNE y UMAP². Reporte las tres proyecciones obtenidas, coloreando los puntos según `HeartDisease`, y comente brevemente sus diferencias.
- (b) **Sensibilidad a hiperparámetros.** Para cada método, varíe un hiperparámetro clave en al menos tres valores y reporte las proyecciones resultantes en una grilla de figuras. En concreto:

² `umap-learn`: <https://umap-learn.readthedocs.io/>

- Para Isomap, varíe `n_neighbors` en $\{5, 15, 50\}$.
- Para t-SNE, varíe `perplexity` en $\{5, 30, 100\}$.
- Para UMAP, en una primera figura varíe `n_neighbors` en $\{5, 15, 50\}$ manteniendo `min_dist` fijo; en una segunda figura varíe `min_dist` en $\{0.0, 0.3, 0.8\}$ manteniendo `n_neighbors` fijo.

Para cada grilla, describa con sus propias palabras qué cambia visualmente al modificar el hiperparámetro.

- (c) **Interpretación.** A partir de las observaciones de la parte (b) y de las funciones objetivo descritas al inicio de la pregunta, indique qué hiperparámetro controla el balance entre estructura local y global en cada método. Discuta, en términos de los p_{ij} y q_{ij} de t-SNE, por qué con `perplexity` muy baja se tienden a generar agrupamientos artificialmente aislados, mientras que con `perplexity` muy alta la estructura tiende a colapsar. Comente también qué papel cumple el parámetro `min_dist` en UMAP dentro de la entropía cruzada que dicho método minimiza, y cómo el valor de `n_neighbors` en Isomap afecta la calidad de la estimación de las distancias geodésicas.
- (d) **Comparación con P1.** ¿Alguna proyección no lineal revela una estructura asociada a **HeartDisease** que las proyecciones lineales de P1 no permitían observar? Argumente apoyándose en los gráficos obtenidos.

P3. Reducción de dimensionalidad como paso previo a la clasificación

Combinaré los métodos de reducción de dimensionalidad estudiados con un clasificador SVM, tomando como referencia la mejor configuración obtenida en la Tarea 4. Si lo prefiere, fije los hiperparámetros del SVM (`class_weight`, `C` y `gamma`) en los valores ganadores de esa tarea.

- (a) **Construcción de los modelos.** Construya, utilizando `sklearn.pipeline.Pipeline`, los siguientes modelos compuestos de *reducción* $\rightarrow$ *clasificador*, ajustando todas las etapas exclusivamente sobre el conjunto de entrenamiento:
- PCA con $d \in \{2, 5, M\}$ (donde M es el número total de variables numéricas) seguido de SVM con kernel lineal.
 - Kernel PCA (`rbf`) con $d = 5$ seguido de SVM con kernel lineal.
 - Fisher Discriminant ($d = 1$) seguido de SVM con kernel lineal.
 - Como modelo de referencia, SVM con kernel `rbf` sobre las variables numéricas originales, en su mejor configuración de la Tarea 4.

Comente brevemente por qué es importante ajustar el transformador únicamente sobre el conjunto de entrenamiento y no sobre todo el dataset.

- (b) **Resultados.** Reporte una tabla con AUC, Accuracy y F1-Score sobre el conjunto de prueba para cada uno de los modelos anteriores. Acompañe la tabla con un gráfico que superponga las curvas ROC de los seis modelos, para facilitar la comparación visual.
- (c) **Kernel PCA seguido de SVM lineal frente a SVM con kernel.** Una de las configuraciones de la parte (a) aplica Kernel PCA con kernel `rbf` y luego un SVM lineal; el modelo de referencia, en cambio, aplica directamente un SVM con kernel `rbf`. Ambos métodos operan sobre la misma matriz

de Gram $K_{ij} = k(x_i, x_j)$. Kernel PCA realiza su descomposición espectral y retiene las primeras d componentes asociadas a los mayores valores propios, mientras que un SVM con kernel utiliza directamente K para resolver el problema dual y construir el clasificador. Discuta sin entrar en derivaciones: ¿operan ambos esquemas sobre el mismo espacio de características implícito? ¿Qué información podría perderse al truncar a $d = 5$ las direcciones de Kernel PCA antes del SVM, y por qué esa pérdida no ocurre cuando el SVM utiliza la matriz K completa? ¿Bajo qué condiciones esperaríamos observar resultados similares entre ambos esquemas?

- (d) **Modelo final.** A partir de los resultados obtenidos en (b) y de la discusión de (c), indique cuál de los modelos anteriores escogería como modelo final. Justifique su elección balanceando rendimiento predictivo, parsimonia (número de dimensiones tras la reducción) y robustez observada al cambiar configuraciones.

P4. Discusión final

- (a) ¿En qué situaciones la reducción de dimensionalidad ayuda al desempeño de un clasificador y en cuáles lo perjudica? Argumente apoyándose en los resultados obtenidos en P3.
- (b) De los métodos vistos a lo largo de la tarea (PCA, Kernel PCA, Fisher Discriminant, Isomap, t-SNE, UMAP), ¿cuál resultó más informativo para **heart.csv** y para qué objetivo (exploración visual, clasificación o interpretabilidad)? Su respuesta no necesita ser un único método.
- (c) Comente las limitaciones generales que observó durante el trabajo: la exclusión de las variables categóricas del análisis, los supuestos implícitos de cada método, la sensibilidad a hiperparámetros y la escalabilidad computacional. ¿Cómo abordaría algunas de estas limitaciones si dispusiera de más tiempo?