

Tarea 5 - MDS7104 Aprendizaje de Máquinas

Felipe Muñoz Marín * 1

Abstract

This work compares linear (PCA, Kernel PCA, Fisher's LDA) and nonlinear (Isomap, t-SNE, UMAP) dimensionality reduction methods on the Heart Failure Prediction dataset (918 observations, 11 features), both for visualization and as preprocessing for classification. Linear methods show strong class overlap, while t-SNE and UMAP reveal a small, nearly pure HEARTDISEASE= 1 cluster invisible in any linear projection, though sensitive to hyperparameter choices. As preprocessing for a linear SVM, PCA ($d = 5$), Kernel PCA ($d = 5$), and Fisher ($d = 1$) achieve similar AUC (~ 0.82), with Fisher matching PCA($d = 5$) using a single dimension—the best trade-off between performance and interpretability among reduced models. All remain below the reference RBF-kernel SVM (AUC=0.9408), mainly due to excluded categorical features.

1. Reducción de dimensionalidad lineal y supervisada

a) Análisis de componentes principales

Se ajustó `sklearn.decomposition.PCA` sobre las cinco variables numéricas estandarizadas del conjunto de entrenamiento (AGE, RESTINGBP, CHOLESTEROL, MAXHR, OLDPEAK). La Tabla 1 reporta los valores propios λ_j obtenidos (correspondientes a la varianza de cada componente) junto con la fracción de varianza explicada (VE) $\lambda_j / \sum_k \lambda_k$ y su acumulado.

Table 1. Valores propios y varianza explicada por componente principal

Componente	Valor propio (λ)	VE (%)	VE acumulada (%)
PC1	1,7106	34,16	34,16
PC2	1,1880	23,73	57,89
PC3	0,8247	16,47	74,36
PC4	0,6997	13,97	88,34
PC5	0,5839	11,66	100,00




Figure 1. Varianza explicada por cada componente y varianza acumulada

Como se observa en el gráfico y tabla anteriores, ninguna componente concentra una fracción dominante de la varianza: PC1 explica apenas un 34,16%, y se requieren las 5 componentes, es decir, la totalidad de las variables numéricas disponibles, para alcanzar el umbral del 90% de varianza acumulada (88,34% con PC4, 100% con PC5). Esto indica que la varianza está repartida de manera relativamente homogénea entre las cinco direcciones, sin una estructura de baja dimensionalidad dominante, por lo que una reducción basada en este criterio no logra una reducción efectiva sobre este conjunto de variables.

A continuación, se proyectan las observaciones del conjunto de entrenamiento sobre las dos primeras componentes principales, coloreando según la variable objetivo HEARTDISEASE.




Figure 2. Dispersión de las observaciones sobre PC1 y PC2, coloreadas por HEARTDISEASE

La Figura 2 muestra que, si bien existe una leve tendencia de las observaciones con HEARTDISEASE=1 (rojo) a con-

centrarse hacia valores positivos de PC1, ambas clases se encuentran fuertemente sobrepuestas en la región central, sin una frontera lineal clara. Esto es consistente con que PC1 y PC2 explican solo un 57,89% de la varianza total (Tabla 1), por lo que la proyección a dos dimensiones diluye parte de la señal discriminante. Más relevante aún, al ser PCA no supervisado, no hay garantía de que las direcciones de máxima varianza coincidan con las que mejor separan las clases.

Finalmente, la Figura 3 muestra el aporte de cada variable original a cada dirección.




Figure 3. Aporte de las variables originales a los vectores propios de PC1 y PC2

De acuerdo con la interpretación geométrica de PCA como dirección de máxima varianza, PC1 está dominada por AGE, OLDPEAK y RESTINGBP (signo positivo) en contraste con MAXHR (signo negativo), por lo que puede interpretarse como un eje de envejecimiento cardiovascular: valores altos combinan mayor edad, mayor depresión del segmento ST y menor frecuencia cardíaca máxima, factores asociados a peor estado cardiovascular. PC2, en cambio, está dominada por CHOLESTEROL y, en menor medida, por RESTINGBP, MAXHR y OLDPEAK, todos con signo positivo; al no presentar contrastes de signo, se interpreta como un eje de magnitud general de los indicadores clínicos, más que de oposición entre variables.

b) Kernel PCA

Se proyectó el conjunto de entrenamiento a dos dimensiones con `sklearn.decomposition.KernelPCA`, usando los kernels RBF y POLY. Para RBF con el valor por defecto ($\gamma = \text{None}$), `sklearn` utiliza $\gamma = 1/M = 0,2$.




Figure 4. PCA lineal vs. Kernel PCA (RBF y polinomial)

Con kernel RBF se observa una mayor dispersión relativa entre clases respecto a PCA lineal, aunque persiste una zona central donde ambas clases se mezclan. Con kernel polinomial ($\text{degree}=3$), en cambio, casi todas las observaciones colapsan en un punto cercano al origen, mientras un puñado de valores extremos se proyecta muy lejos: esto es consecuencia de que $k(x, y) = (x^\top y + c)^d$ crece muy rápido con la norma de x, y , por lo que la escala de la proyección queda dominada por unos pocos outliers, en lugar de reflejar la estructura general de los datos. En ningún caso se observa una separación lineal clara entre clases.




Figure 5. Variación de γ en el kernel RBF

El kernel RBF, $k(x, y) = \exp(-\gamma \|x - y\|^2)$, mide similitud según la distancia entre puntos: un γ pequeño induce similitudes que decaen lentamente, por lo que puntos relativamente lejanos siguen considerándose similares (similitud global), mientras que un γ grande hace que la similitud decaiga muy rápido, considerando similares solo a puntos prácticamente idénticos (similitud local). Con $\gamma = 0,01$ la proyección es difusa y similar en escala a PCA lineal; al aumentar a $\gamma = 1$, la mayoría de las observaciones, colapsan en un punto cercano al origen (al ser mutuamente similares en sentido local), mientras que las observaciones más atípicas de la clase 0 se dispersan hacia los extremos.




Figure 6. Variación del grado del polinomio en el kernel poly

Al aumentar el grado del polinomio, el problema descrito anteriormente se intensifica: con $\text{degree}=5$, prácticamente todos los puntos se concentran cerca del origen y la escala del gráfico llega a 100, dominada por un único outlier. Esto vuelve la proyección poco interpretable y no aporta separabilidad adicional respecto a PCA lineal o Kernel PCA RBF.

c) Discriminante de Fisher (FLD)

Se ajustó LINEARDISCRIMINANTANALYSIS sobre las variables numéricas estandarizadas del conjunto de entrenamiento, obteniendo la proyección unidimensional en el siguiente gráfico.




Figure 7. Proyección de Fisher (1D) vs. primera componente principal (PC1)

Para $K = 2$ clases, $S_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^\top$ tiene rango 1, por lo que el problema generalizado $S_B w = \lambda S_W w$ posee un único valor propio no nulo; en general S_B tiene rango a lo más $K - 1$, por lo que FLD entrega como máximo $C - 1$ direcciones (en este caso, exactamente una).

A diferencia de PCA, que elige la dirección de máxima varianza total sin considerar las clases, Fisher corrige por S_W^{-1} , “blanqueando” la dispersión intra-clase para que la única señal relevante sea la separación entre medias $\mu_1 - \mu_2$. Si las direcciones de máxima varianza no coinciden con $\mu_1 - \mu_2$, PC1 puede estar capturando varianza que es “ruido” para la clasificación, mientras Fisher la ignora por construcción.

Sin embargo, al cuantificar la separación con el criterio $J(a) = (m_1 - m_0)^2 / (s_0^2 + s_1^2)$, se obtiene $J_{\text{Fisher}} = 0,0025$ frente a $J_{\text{PC1}} = 0,0019$: si bien Fisher mejora la separación respecto a PC1 (consistente con el argumento anterior, pues maximiza J por construcción), la mejora es marginal y ambas proyecciones siguen mostrando un fuerte solapamiento visual entre clases. Esto sugiere que, para este conjunto de variables, la dirección de máxima varianza no se aleja demasiado de $S_W^{-1}(\mu_1 - \mu_2)$, y que ninguna proyección lineal a una dimensión logra capturar una señal fuertemente discriminante entre clases.

2. Reducción de dimensionalidad no lineal y sensibilidad a hiperparámetros

a) Aplicación inicial

Se proyectó el conjunto de entrenamiento a dos dimensiones con `sklearn.manifold` y `umap-learn`, us-

ando Isomap, t-SNE y UMAP², con los parámetros por defecto de cada método (`N_NEIGHBORS= 15`, `PERPLEXITY= 30`, `MIN_DIST= 0, 1`).




Figure 8. Proyecciones no lineales: Isomap, t-SNE y UMAP

t-SNE genera dos cúmulos bien diferenciados: el cúmulo principal (superior) mezcla ambas clases de forma similar a PCA, pero el cúmulo pequeño aislado (inferior derecha) está compuesto en su mayoría por observaciones HEART-DISEASE=1, lo que sugiere la existencia de un subgrupo de pacientes con un perfil clínico claramente distintivo respecto al resto.

UMAP exhibe un patrón similar: una isla pequeña, predominantemente de la clase 1, separada de una masa principal continua donde ambas clases se solapan considerablemente, preservando algo más de la estructura global que t-SNE.

Isomap, en cambio, no fuerza una separación en cúmulos discretos sino que despliega los datos según su geometría, generando una proyección en forma de abanico donde se aprecia una región (derecha) con mayor concentración de la clase 1, pero sin una frontera clara. Su forma global es comparable a la de PCA (Figura 2), lo que sugiere que el dataset no posee una estructura de variedad fuertemente curva.

b) Sensibilidad a hiperparámetros

Isomap: variación de `n_neighbors` en {5, 15, 50}.




Figure 9. Isomap - sensibilidad a `n_neighbors`

Con $k = 5$, el grafo de vecindad es más restrictivo y tiende a generar componentes poco conectadas entre sí, lo que se refleja en una proyección con dos masas claramente separadas. Al aumentar a $k = 50$, el grafo incorpora aristas entre

puntos lejanos en la variedad, lo que aproxima las distancias geodésicas (longitud del camino más corto entre dos puntos sobre una superficie curva) a distancias euclídeas directas: la proyección resultante es más compacta y uniforme, perdiendo la estructura en dos grupos y pareciéndose más a una proyección lineal tipo PCA.

t-SNE: variación de perplexity en {5, 30, 100}.




Figure 10. t-SNE - sensibilidad a perplexity

La perplejidad determina el número efectivo de vecinos considerados al construir $p_{j|i}$. Con $\text{perplexity}=5$, el algoritmo se enfoca en distancias hiperlocales y fragmenta los datos en numerosos cúmulos pequeños y artificiales. Con $\text{perplexity}=100$ (cercano al tamaño muestral), casi todos los puntos se consideran vecinos entre sí, priorizando la estructura global por sobre los detalles locales, lo que produce una nube más uniforme y dispersa, con menos definición de sub-cúmulos.

UMAP: variación de $n_neighbors$ en {5, 15, 50} ($\text{min_dist}=0,1$ fijo).




Figure 11. UMAP - sensibilidad a $n_neighbors$

Con k bajo, UMAP enfatiza la estructura local y las observaciones se dividen en subgrupos compactos, revelando posible estructura interna dentro de cada clase. Al aumentar k , el algoritmo prioriza la organización global por sobre las diferencias locales: los subgrupos se fusionan en masas continuas más grandes, aunque persiste un pequeño cúmulo aislado de la clase 1.

UMAP: variación de min_dist en {0,0; 0,3; 0,8} ($n_neighbors=15$ fijo).




Figure 12. UMAP - sensibilidad a min_dist

min_dist controla qué tan cerca pueden quedar los puntos en la proyección. Con $\text{min_dist}=0,0$, los puntos similares se ubican casi superpuestos, generando estructuras densas y delgadas (como “filamentos”). Con $\text{min_dist}=0,8$, UMAP impone una separación mínima entre todos los puntos, forzándolos a distribuirse de forma más uniforme: las clases 0 y 1 se expanden y se mezclan visualmente en una región más amplia, perdiendo la compacidad observada con min_dist bajo.

c) Interpretación

En los tres métodos, los hiperparámetros que controlan directamente el balance entre estructura local y global son: para Isomap y UMAP es $n_neighbors$, y para t-SNE es perplexity .

En Isomap, $n_neighbors$ determina la calidad de las geodésicas estimadas δ_{ij} (las distancias reales sobre la variedad) vía caminos más cortos en el grafo de vecinos. Un k muy bajo puede dejar el grafo desconectado o con componentes poco vinculadas, de modo que las distancias entre ellas no se estiman correctamente (lo que explica la separación en dos masas observada en la Figura 9). Un k muy alto introduce aristas directas entre puntos lejanos sobre la variedad que aproximan δ_{ij} por la distancia euclídea en lugar del camino geodésico real, acercando el resultado de Isomap al de PCA.

En t-SNE, con perplexity baja, σ_i se ajusta para que pocos vecinos concentren casi toda la masa de $p_{j|i}$; al simetrizar, p_{ij} queda prácticamente nulo entre puntos de distintos sub-grupos locales, por lo que la divergencia de Kullback-Leibler $D_{KL}(P||Q)$ no penaliza colocarlos lejos en $\mathbb{R}^2$, y la optimización separa los datos en numerosos cúmulos artificialmente aislados. Con perplexity alta, σ_i crece hasta que casi todos los puntos tienen $p_{j|i} > 0$ similar entre sí: P se vuelve casi uniforme, $D_{KL}(P||Q)$ ya no distingue vecindades finas, y la estructura colapsa hacia una nube difusa sin sub-grupos definidos.

En UMAP, min_dist interviene en $w_{ij} = (1 + a\|y_i - y_j\|^{2b})^{-1}$ (los parámetros a, b se calibran a partir de min_dist), que aparece en ambos términos de la entropía cruzada:

$$C(Y) = \sum_{i \neq j} \left[v_{ij} \log \frac{v_{ij}}{w_{ij}} + (1 - v_{ij}) \log \frac{1 - v_{ij}}{1 - w_{ij}} \right]$$

Con `min_dist` bajo, w_{ij} puede acercarse a 1 incluso para $\|y_i - y_j\| \rightarrow 0$, permitiendo que puntos similares (v_{ij} alto) colapsen casi al mismo punto sin incurrir en costo del primer término. Con `min_dist` alto, w_{ij} se mantiene acotado lejos de 1 aún a distancia cero, lo que obliga a separar todos los puntos para mantener w_{ij} razonablemente alto, dispersando la proyección.

d) Comparación con P1

Las proyecciones de t-SNE y UMAP (Figura 8) revelan un sub-grupo de observaciones con `HEARTDISEASE=1` que se separa de manera nítida del resto de los datos, formando un cúmulo casi puro y bien diferenciado. Esta estructura no es visible en ninguna de las proyecciones lineales reportadas en P1, pues ni PCA (Figura 2), ni Kernel PCA con RBF o polinomial (Figura 4), ni la proyección de Fisher (Figura 7) muestran un grupo aislado equivalente, sino más bien un solapamiento difuso y continuo entre ambas clases.

Notar que PCA, Kernel PCA y Fisher buscan direcciones globales (de máxima varianza o de máxima separación de medias) que actúan sobre todo el conjunto de datos por igual, por lo que un sub-grupo minoritario y geométricamente distinto puede no alinearse con ninguna de esas direcciones globales y queda “disuelto” dentro de la nube principal. En cambio, t-SNE y UMAP construyen sus representaciones a partir de relaciones de vecindad locales: si este sub-grupo de pacientes presenta un perfil clínico (combinación de variables numéricas como `OLDPEAK`, `MAXHR` y/o `CHOLESTEROL`) suficientemente distinto al de los demás, de modo que sus vecinos más cercanos son principalmente otros miembros del mismo sub-grupo, ambos métodos lo aislarán como una región propia del espacio reducido, independientemente de su tamaño relativo o de su contribución a la varianza global.

3. Reducción de dimensionalidad como paso previo a la clasificación

a) Construcción de los modelos

Usando `SKLEARN.PIPELINE.PIPELINE`, se construyen los siguientes modelos compuestos de reducción → clasificador, ajustando todas las etapas exclusivamente sobre el conjunto de entrenamiento:

- PCA con $d \in \{2, 5, M\}$ (donde $M = 5$ es el número total de variables numéricas) seguido de SVM con kernel lineal.

- Kernel PCA (rbf) con $d = 5$ seguido de SVM con kernel lineal.
- Fisher Discriminant ($d = 1$) seguido de SVM con kernel lineal.
- Modelo de referencia: SVM con kernel rbf en su mejor configuración de la Tarea 4 ($C = 1$, `GAMMA='scale'`, `CLASS_WEIGHT=None`), aplicado sobre el conjunto completo de variables (numéricas estandarizadas más variables categóricas codificadas como dummies).

Cabe destacar que los modelos con reducción operan únicamente sobre las cinco variables numéricas estandarizadas, mientras que el modelo de referencia utiliza el conjunto completo de variables.

Ajustar los transformadores (PCA, `KERNELPCA`, LDA, `STANDARDSCALER`) únicamente sobre el conjunto de entrenamiento evita data leakage: si la media, varianza, componentes principales o direcciones discriminantes se calculan usando también las observaciones de test, el modelo accede indirectamente a información sobre la distribución del conjunto de prueba durante el entrenamiento. Esto produce una estimación optimista del desempeño (las métricas de test dejan de ser una medida honesta de generalización a datos no vistos), pues el conjunto de prueba ya influyó en la transformación aplicada a sí mismo.

b) Resultados

Se reportan los siguientes resultados:

Table 2. Comparación de desempeño de los modelos evaluados

Modelo	AUC	Accuracy	F1-Score
PCA ($d = 2$) + SVM lineal	0.7622	0.7065	0.7404
PCA ($d = 5$) + SVM lineal	0.8274	0.7772	0.7960
KPCA (RBF, $d = 5$) + SVM lineal	0.8190	0.7283	0.7685
Fisher ($d = 1$) + SVM lineal	0.8269	0.7663	0.7882
SVM RBF (referencia)	0.9408	0.8804	0.8972

Curvas ROC — Comparación de modelos




Figure 13. Curvas ROC de los seis modelos comparados

El modelo de referencia obtiene el mayor AUC y F1-Score, lo cual es esperable considerando que, además de usar un kernel RBF, opera sobre el conjunto completo de variables, mientras que el resto de los modelos solo dispone de las cinco variables numéricas.

PCA ($d = 2$) obtiene el desempeño más bajo entre los modelos reducidos, consistente con el fuerte solapamiento de clases observado en la Figura 2: al retener solo dos direcciones de varianza, se pierde información discriminante presente en las componentes restantes.

Por otro lado, PCA ($d = 5$), KPCA (rbf, $d = 5$) y Fisher ($d = 1$) obtienen un AUC muy similar entre sí y curvas ROC prácticamente superpuestas. Este resultado tiene sentido, pues PCA con $d = M = 5$ es solo una rotación ortogonal de las variables originales (sin pérdida de información), por lo que un SVM lineal sobre esta proyección debería rendir igual que uno entrenado directamente sobre las cinco variables numéricas. KPCA (rbf, $d = 5$) queda levemente por debajo, sugiriendo que truncar a $d = 5$ en el espacio inducido por el kernel no aporta una ventaja clara sobre el espacio lineal original para este dataset. Y Fisher ($d = 1$), pese a usar una sola dimensión, alcanza un AUC casi idéntico al de PCA($d = 5$). Lo anterior es consistente con lo observado en P1(c), donde la proyección de Fisher mejoraba solo marginalmente la separación respecto a PC1, pero por construcción concentra en esa única dirección casi toda la señal discriminante lineal disponible en las variables numéricas.

c) Kernel PCA seguido de SVM lineal frente a SVM con kernel

Ambos esquemas operan sobre la misma matriz de Gram $K_{ij} = k(x_i, x_j)$, que representa los productos internos $\langle \phi(x_i), \phi(x_j) \rangle_{\mathcal{H}}$ en el espacio de características inducido por el kernel RBF. Dicho esto, sí comparten el mismo espacio de características implícito $\mathcal{H}$: Kernel PCA realiza la descomposición espectral de K y proyecta las observaciones sobre las d direcciones principales de $\mathcal{H}$, mientras que el SVM con kernel resuelve directamente el problema dual usando K completa, sin proyectar explícitamente.

La diferencia central está en qué información de $\mathcal{H}$ se conserva. Al truncar a $d = 5$ componentes en Kernel PCA, se retienen únicamente las direcciones de $\mathcal{H}$ asociadas a los mayores valores propios, descartando el resto. Si la dirección que mejor separa las clases no coincide con esas primeras direcciones de máxima varianza, esa información discriminante se pierde antes de llegar al SVM lineal. El SVM con kernel, en cambio, no descarta ninguna dirección de $\mathcal{H}$ a priori: el problema dual permite que el hiperplano óptimo se construya usando toda la información contenida en K , encontrando la combinación de direcciones (no necesariamente las de mayor varianza) que maximiza el margen

entre clases.

Se esperarían resultados similares entre ambos esquemas si la dimensión d retenida en Kernel PCA fuese suficientemente grande como para capturar las direcciones de $\mathcal{H}$ relevantes para la separación de clases, en el límite, si $d = N$ (rango completo de K), Kernel PCA preserva toda la información de $\mathcal{H}$ y un SVM lineal sobre esa proyección completa debería aproximar el desempeño del SVM con kernel. De forma más general, ambos esquemas tenderán a coincidir cuando las direcciones de máxima varianza de $\mathcal{H}$ y las direcciones relevantes para la separación de clases estén razonablemente alineadas, de modo que truncar a pocas componentes no descarte información discriminante importante.

d) Modelo final

De los modelos con reducción de dimensionalidad, se escoge Fisher ($d = 1$) + SVM lineal como modelo final. Su AUC y F1-Score son prácticamente idénticos a los de PCA($d = 5$)+SVM lineal (Tabla 2), pero logrados con una sola dimensión en lugar de cinco, es decir, con una compresión de información mucho mayor sin sacrificio de desempeño. Esto se relaciona con lo discutido en (b), al ser un método supervisado, Fisher concentra en su única dirección casi toda la señal discriminante lineal disponible en las variables numéricas, mientras que PCA($d = 5$) requiere conservar la totalidad de las direcciones, es decir, este último, no logra ninguna reducción efectiva para alcanzar un desempeño equivalente.

En términos absolutos, el SVM RBF de referencia sigue siendo superior, en parte por el uso de kernel no lineal y, sobre todo, por incorporar las variables categóricas no consideradas en los modelos reducidos. Tal como se discutió en (c), al no truncar ninguna dirección de $\mathcal{H}$ a priori, este modelo aprovecha toda la información disponible en la matriz de Gram. Sin embargo, al considerar parsimonia e interpretabilidad, Fisher($d = 1$)+SVM lineal ofrece la mejor relación entre ambos criterios dentro de los modelos evaluados.

4. Discusión final

a) Situaciones donde la reducción de dimensionalidad ayuda y perjudica al desempeño de un clasificador

La reducción de dimensionalidad ayuda principalmente cuando existe redundancia o ruido en las variables originales: al eliminar multicolinealidad y comprimir la información relevante en menos direcciones, se reduce el riesgo de sobreajuste y se disminuye el costo computacional, sin necesariamente sacrificar desempeño. Un ejemplo se observa en P3(b) (Tabla 2): Fisher($d = 1$) alcanza un AUC prácticamente idéntico al de PCA($d = 5$), pero usando una sola dimensión en lugar de las cinco originales, evidencia

de que, cuando la dirección discriminante relevante es capturada adecuadamente, la reducción no implica pérdida de desempeño.

Por el contrario, la reducción perjudica cuando se descartan direcciones que, aunque sean de baja varianza, contienen información discriminante relevante. Esto también se logra observar al comparar $\text{PCA}(d = 2)$ con $\text{PCA}(d = 5)$ en P3(b) (Tabla 2): el AUC cae de 0,8274 a 0,7622 al retener solo las dos primeras componentes, pues las direcciones descartadas, que son de menor varianza, aportaban señal útil para separar las clases. En estos casos, el riesgo es mayor cuando las direcciones de máxima varianza no coinciden con las direcciones que mejor separan las clases, la cual es una situación más probable en problemas con clases minoritarias o estructura compleja, donde la señal discriminante puede concentrarse en componentes de baja varianza global.

b) Modelo más informativo para heart.csv y para qué objetivo

- **Exploración visual:** El método más informativo es t-SNE. Como se discutió en P2(a) y P2(d), estos métodos revelaron un sub-grupo de pacientes con $\text{HEARTDISEASE}=1$ que forma un cúmulo en su mayoría aislado (Figura 8), estructura que no era visible en ninguna proyección lineal. PCA, en cambio, es útil como complemento para entender la estructura global de los datos y la contribución de cada variable original (Figura 3), aunque no logra separar visualmente las clases.
- **Clasificación:** De acuerdo con la Tabla 2, $\text{PCA}(d = 5)$ y $\text{Fisher}(d = 1)$ son los modelos con mejor generalización (mayor AUC y F1-Score) entre los reducidos. Como se argumentó en P3(d), $\text{Fisher}(d = 1)$ es preferible por lograr un desempeño equivalente con una sola dimensión, por lo que es el más adecuado si el objetivo es clasificar de forma eficiente.
- **Interpretabilidad:** Fisher es el más interpretable, pues su única dirección se interpreta como la combinación lineal de variables que maximiza la separación entre clases, lo que permite identificar de inmediato qué variables contribuyen más al diagnóstico. PCA también es interpretable a través de sus loadings (Figura 3), aunque sus componentes no están orientadas hacia la separación de clases. Kernel PCA, t-SNE y UMAP, en cambio, operan en espacios implícitos o no paramétricos, dificultando relacionar las proyecciones con las variables originales.

c) Limitaciones generales observadas

- **Exclusión de variables categóricas:** Los métodos de reducción se aplicaron únicamente sobre las cinco variables numéricas estandarizadas, excluyendo variables

categóricas como `CHESTPAINTYPE`, `EXERCISEANGINA` o `ST_SLOPE`. Esto explica en gran parte la brecha observada en P3(b) entre los modelos reducidos ($\text{AUC} \approx 0,82$) y el SVM RBF de referencia ($\text{AUC} = 0,9408$). Este último, al incorporar las variables categóricas, accede a información discriminante adicional que ningún modelo basado solo en las numéricas puede capturar. Esto sugiere que, para este dataset, las variables categóricas aportan señal relevante para distinguir `HEARTDISEASE`.

- **Supuestos implícitos:** Cada método impone supuestos que pueden no ajustarse a los datos: PCA y Kernel PCA asumen que la información relevante se concentra en las direcciones de mayor varianza, lo cual, como se vio en P3(c), no garantiza alinearse con la separación entre clases; Fisher asume covarianzas intra-clase similares (S_W común) y que una proyección lineal basta para separar las clases; Isomap asume que la variedad es localmente isométrica a un convexo, lo cual puede no cumplirse si los datos no presentan una geometría curva clara (P2-a); y t-SNE/UMAP priorizan la preservación de vecindades locales por sobre las distancias globales, por lo que las distancias entre cúmulos en sus proyecciones no deben interpretarse literalmente.
- **Sensibilidad a hiperparámetros:** Como se observó en P2(b), los resultados de Isomap, t-SNE y UMAP dependen fuertemente de `n_neighbors`, `perplexity` y `min_dist`, por lo que, pequeñas variaciones pueden cambiar completamente la apariencia de la proyección (de múltiples cúmulos fragmentados a una nube difusa, o viceversa). Esto dificulta obtener conclusiones robustas sin explorar un rango de valores, y en la práctica requiere criterio del analista para elegir configuraciones razonables.
- **Escalabilidad computacional:** Los métodos de Isomap, t-SNE, UMAP y Kernel PCA tienen un costo computacional considerablemente mayor que PCA o Fisher: Isomap requiere calcular caminos más cortos sobre un grafo de N vecinos, Kernel PCA y t-SNE operan sobre matrices $N \times N$, y t-SNE en particular es notoriamente lento para N grande. Si bien en este trabajo $N \approx 734$ no representó un problema práctico, en datasets de mayor tamaño estos métodos pueden volverse prohibitivos, siendo UMAP generalmente la alternativa más escalable entre los no lineales.
- **Posibles extensiones:** Con más tiempo, se podría: (i) aplicar la reducción sobre el conjunto completo de variables (numéricas y categóricas) para una comparación más justa con el modelo de referencia; (ii) explorar combinaciones reducción+kernel adicionales (como Isomap o UMAP como preprocesamiento para SVM);

y (iii) realizar una búsqueda sistemática de hiperparámetros (vía validación cruzada) para los métodos no lineales, en lugar de la exploración puntual realizada en P2(b).

Referencias

Scikit-learn Developers. (s.f.). PCA. <https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>

Scikit-learn Developers. (s.f.). KernelPCA. <https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.KernelPCA.html>

Scikit-learn Developers. (s.f.). LinearDiscriminantAnalysis. https://scikit-learn.org/stable/modules/generated/sklearn.discriminant_analysis.LinearDiscriminantAnalysis.html

Scikit-learn Developers. (s.f.). Pipeline. <https://scikit-learn.org/stable/modules/generated/sklearn.pipeline.Pipeline.html>